

UNIVERSIDAD COMPLUTENSE DE MADRID

Máster en Data Science, Big Data & Business Analytics

TRABAJO FIN DE MÁSTER

Determinantes y predicción del salario de las mujeres asalariadas en Argentina (2024-2026)

Una comparación con Brasil y España y una herramienta de referencia salarial



Patricia Elizabeth Olguín

Opción elegida: análisis de un dataset (orientación data scientist)

Tutores: Carlos Ortega y Santiago Mota

Septiembre de 2026

Índice

Resumen ejecutivo	1
1. Motivación y aporte del trabajo	2
2. Datos y variable objetivo	3
3. Preparación de los datos	4
4. Modelos y validación en el futuro inmediato	5
5. ¿Qué determina el salario de las mujeres?	7
6. Territorio, recursos naturales y poder de compra	8
7. Brecha de género y transparencia retributiva	10
8. Argentina frente a Brasil y España	11
9. Del modelo a la herramienta	13
10. Conclusiones, limitaciones y líneas futuras	16
Bibliografía	18
Anexo A. Variables seleccionadas	19
Anexo B. Detalle de los modelos	20
Anexo C. Hogar, cuidados y sesgo de selección	20
Anexo D. Preparación de las bases de Brasil y España	20
Anexo E. Reproducibilidad y enlaces	21
Anexo F. Notebook ejecutado	21

Resumen ejecutivo

Este trabajo identifica qué características personales, laborales, del hogar y del territorio se asocian con salarios más altos de las mujeres asalariadas en Argentina, comprueba si esa estructura sirve para predecir el salario en el futuro inmediato y la convierte en una **herramienta de referencia salarial** para empresas y organismos públicos. La fuente son los microdatos de la Encuesta Permanente de Hogares (EPH) del INDEC, nueve trimestres entre 2024 y 2026, más de 95.000 registros de asalariados; la comparación con Brasil y España usa las encuestas equivalentes de esos países.

La EPH es la fuente más usada para estudiar el mercado de trabajo argentino, pero sus cuadros publicados no responden preguntas concretas de negocio: cuánto paga el mercado por un perfil determinado, cuánto de la diferencia salarial entre ciudades es costo de vida o si el salario alcanza para sostener a una familia. El aporte del trabajo es obtener esa información indirecta combinando los microdatos con la canasta básica regional del INDEC y técnicas de aprendizaje automático interpretables.

Cinco hallazgos principales

- 1. El empleo pesa más que la formación.** Las condiciones del puesto (registro, jornada, ocupación y actividad), que dependen de las empresas y de la política laboral, concentran el 63% de lo que explica el modelo; la educación y la experiencia de la trabajadora, el 14%; el territorio y el hogar, el 23%.
- 2. El modelo predice a un año con la precisión habitual en ecuaciones salariales.** LightGBM explica el 44% de la variabilidad del salario relativo en un trimestre que nunca vio (1T2026), frente al 40% de la regresión lineal. La composición de la población es estable, pero la prima del empleo registrado cayó del 34% al 19% en un año: hay que reentrenar cada trimestre.
- 3. La desventaja salarial del Norte es sobre todo costo de vida.** A igual perfil, la distancia entre regiones es de 39 puntos en pesos y de 9 al descontar la canasta regional. Vaca Muerta ya eleva los salarios reales de las mujeres de Neuquén; los polos mineros todavía no.
- 4. El salario mediano no alcanza para sostener a una familia.** A jornada completa cubre 0,75 veces la canasta básica de una familia tipo (welfare ratio de Allen); solo con título superior la supera.
- 5. La brecha de género a igual perfil supera el 5% de la Directiva europea** en Argentina (6,4%), en España (11%) y en Brasil (15%), aunque la brecha observada sea menor.

El resultado productivo es una **aplicación web** (tfm-olguin-patricia.streamlit.app) que, para cualquier perfil, devuelve el salario de mercado con una banda del 90%, indica si ese salario alcanza para vivir, audita la nómina de una empresa frente al mercado y frente al umbral de la Directiva (UE) 2023/970, y muestra los resultados territoriales y comparados.

1. Motivación y aporte del trabajo

1.1 Por qué estudiar el salario de las mujeres

El salario real es un indicador del **bienestar material** de las trabajadoras. La historia económica lo usa para comparar niveles de vida entre épocas y países: Robert Allen (2001) propuso el *welfare ratio*, el cociente entre lo que gana un trabajador a tiempo completo y lo que cuesta sostener a una familia con una canasta básica. En Argentina la participación laboral femenina creció durante décadas, pero la mayoría de los estudios se concentró en la brecha de género o en la participación; menos atención recibieron los **factores que elevan el salario de las propias mujeres** y su estabilidad en el tiempo.

La pregunta tiene además interés práctico. Una empresa que quiere retener talento necesita saber si paga según el mercado; un organismo público necesita saber qué parte de la desigualdad salarial depende de factores sobre los que puede actuar. Y desde 2026 las empresas europeas deben justificar las brechas salariales de género superiores al 5% a igual trabajo: una herramienta que compare cada salario con el mercado a igual perfil responde a esa exigencia.

1.2 Preguntas de investigación

Pregunta central: ¿qué características personales, laborales, del hogar y del territorio se asocian con salarios más altos de las mujeres asalariadas en Argentina, y sirve esa estructura para predecir el salario en el futuro inmediato (un año o menos)? ¿Son esos determinantes propios de Argentina o se repiten en Brasil y España?

De ella se derivan preguntas que los cuadros publicados de la EPH no responden y que este trabajo sí:

- ¿Cuánto paga el mercado por un perfil concreto, y con qué margen?
- ¿Cuánto de la diferencia salarial entre ciudades desaparece al descontar el costo de vida?
- ¿Llega la riqueza de Vaca Muerta y de la minería al salario de las mujeres?
- ¿Alcanza el salario de una asalariada para sostener a una familia?
- ¿Cuánto de la brecha de género no se explica por el perfil, y supera el umbral del 5% de la Directiva europea?

1.3 Qué aporta respecto de un análisis habitual

- **Información que no existe en los cuadros publicados:** salario de mercado por perfil, prima salarial real de cada ciudad, efecto de los polos de recursos naturales y *welfare ratio* por perfil.
- **Variables que la encuesta no pregunta,** construidas con todos los miembros del hogar: hijos propios, educación de la pareja y clima educativo.
- **La estabilidad como hipótesis, no como supuesto:** validación fuera de tiempo, origen móvil, índice de estabilidad poblacional y prueba de Wald.
- **Un producto utilizable:** bandas salariales con garantía estadística y una aplicación que no requiere conocimientos técnicos.

1.4 Antecedentes

El trabajo se apoya en tres tradiciones. La primera es la **ecuación de Mincer** (1974), que relaciona el logaritmo del salario con la educación y la experiencia y sigue siendo la referencia de la economía laboral para medir cuánto "paga" cada característica. La segunda es la literatura sobre **brechas de género:** la descomposición de Oaxaca (1973) separa la brecha explicada por el perfil de la no explicada, y los estudios recientes muestran que la parte no explicada y la "penalización por hijos" dominan las brechas actuales (Blau y Kahn, 2017; Kleven, Landais y Sjøgaard, 2019). La tercera es la **historia económica de los salarios reales:** el *welfare ratio* de Allen (2001) se aplicó

a América Latina para comparar niveles de vida de largo plazo (Arroyo Abad, Davies y van Zanden, 2012) y, en trabajos previos de la autora, a los salarios reales de varones y mujeres de Mendoza entre 1890 y mediados del siglo XX (Olguín y Bragoni, 2020, 2023 y 2025; Olguín, 2025; Olguín et al., 2026). Este trabajo lleva ese enfoque a los microdatos actuales.

Del lado de la ciencia de datos, Mullainathan y Spiess (2017) muestran que el aprendizaje automático es útil para **predecir**, mientras que los coeficientes de la econometría clásica siguen siendo necesarios para **interpretar**. El trabajo combina ambos enfoques: LightGBM para predecir y validar la importancia de las variables, y la ecuación de Mincer para traducirlas a efectos porcentuales que un gerente o un funcionario puedan leer.




Figura 1. Esquema del trabajo: de los microdatos a la herramienta, y la comparación internacional.

2. Datos y variable objetivo

2.1 Fuentes

Fuente	Organismo	Uso en el trabajo
Encuesta Permanente de Hogares (bases de personas y hogares), 1T2024-1T2026	INDEC (Argentina)	Base principal: 9 trimestres, unas 45.000 personas por trimestre en 31 aglomerados urbanos
Canasta Básica Total por región, nov-2023 a jun-2026	INDEC	Costo de vida regional y welfare ratio
Índice de Precios al Consumidor	INDEC	Salarios de 2024 a precios constantes para la comparación internacional
Paridad de poder adquisitivo del consumo de los hogares	Banco Mundial	Conversión de salarios a dólares internacionales
PNAD Continua, 1T2024-2T2026	IBGE (Brasil)	Comparación internacional
Encuesta de Condiciones de Vida 2024-2025 y Encuesta de Estructura Salarial 2022	INE (España)	Comparación internacional y validación con nóminas

Tabla 1. Fuentes de datos. Todos los archivos se descargan de los sitios oficiales y se leen desde la carpeta TFM de Google Drive (enlace en el Anexo E).

Se eligió el período 2024-2026 porque es el más reciente disponible, posterior a la pandemia, y porque permite reservar el último trimestre (1T2026) como **futuro que el modelo no ve**. Es un período de fuerte cambio macroeconómico (devaluación de diciembre de 2023 y desinflación posterior), lo que convierte la estabilidad del modelo en una prueba exigente.

2.2 Población de estudio y variables del hogar

La población de estudio son las personas asalariadas de 18 a 60 años con salario y horas válidos: unos 97.000 registros, 46.000 de ellos de mujeres. Antes de filtrar se usa la base de personas **completa** para construir variables que la encuesta no pregunta a la trabajadora: sus hijos propios (a partir del parentesco con el jefe o jefa del hogar), la educación y la ocupación de su pareja y el *clima educativo* del hogar (años de educación de los otros adultos, un indicador del origen social). También se conserva a todas las mujeres de 18 a 60 años, trabajen o no, para estudiar cómo los hijos afectan la decisión de trabajar.

2.3 Variable objetivo: salario relativo

Entre 2024 y 2026 el salario nominal por hora se multiplicó por más de tres. Para que el modelo aprenda **posiciones** y no inflación, la variable objetivo es el logaritmo del salario horario dividido por la mediana de todos los asalariados del mismo trimestre:

$$y = \log(\text{salario horario} / \text{mediana del trimestre})$$

Un valor de 0 significa cobrar la mediana; 0,10, alrededor de un 10% más. La medida neutraliza la inflación, la estacionalidad y la volatilidad macroeconómica sin depender de un deflactor. El salario se mide por hora para comparar jornadas distintas: las mujeres trabajan más a tiempo parcial por las tareas de cuidado. Los niveles reales se recuperan después, con la canasta básica (sección 6).

2.4 Primera mirada a los datos




Figura 2. Salario horario nominal y relativo de las mujeres asalariadas por trimestre (izquierda) y salario relativo según educación y registro, 3T2025-1T2026 (derecha).

La Figura 2 resume por qué se eligió la variable objetivo y cuáles son las relaciones más visibles. A la izquierda, el salario horario nominal mediano de las asalariadas se multiplicó por 3,3 en dos años, mientras que su **posición relativa** (la mediana y el rango intercuartílico del salario relativo) se mantuvo casi constante: la variable objetivo elimina la inflación sin perder la desigualdad entre trabajadoras. A la derecha aparecen los dos determinantes que el modelo confirmará: la **educación** y, sobre todo, el **registro** del empleo. Una asalariada con secundaria completa y empleo registrado cobra por hora cerca de la mediana; sin registro, un 36% menos. Con título superior, la diferencia entre registradas y no registradas es de casi 40 puntos.

La exploración completa (distribuciones, valores perdidos, asociación de cada variable con el salario y comparación entre trimestres) está en el notebook, secciones 3 y 4 (Anexo F).

3. Preparación de los datos

La base unida tiene 319 variables. La preparación siguió los pasos del módulo de Minería de datos, con una decisión explícita para cada grupo de variables:

Paso	Criterio	Resultado
Selección conceptual	Se excluyen identificadores, ponderadores, variables que definen la población y, sobre todo, los ingresos que contienen el salario (evitar fuga de información)	319 → 148 candidatas
Códigos y preguntas que no aplican	Códigos 9/99 = no sabe/no responde → nulo; se eliminan las preguntas dirigidas a desocupados o independientes (>90% 'no corresponde')	148 → 141
Ingeniería de variables	Años de educación y experiencia potencial (Mincer); ocupación (CNO-2001) y actividad (CAES) agrupadas; hacinamiento; tareas del hogar	26 variables nuevas
Poca información y redundancia	Casi constantes, >40% de nulos no estructurales, categorías con <100 casos → 'Otros'; pares con asociación >0,90 (Pearson o V de Cramér)	97 candidatas finales
Atípicos	Winsorización en los percentiles 1 y 99, calculados solo con el entrenamiento	Sin pérdida de registros
Perdidos	Nulos estructurales (sin pareja, sin otros adultos): imputación con la mediana del entrenamiento + indicador '_faltante'	Se conserva por qué falta el dato

Tabla 2. Decisiones de depuración (detalle en el notebook, sección 3; diccionario en el Anexo A).

Dos decisiones merecen destacarse. La primera: **los nulos no se eliminan**. El 57% de las asalariadas no tiene pareja en el hogar; borrar esos registros habría sesgado la muestra hacia las mujeres en pareja. La segunda: todas las decisiones se toman **solo con los datos de entrenamiento**, para que la evaluación en el futuro sea honesta. Antes de modelar, el ranking de la V de Cramér con dos variables aleatorias de control confirmó que todas las candidatas tienen relación con el salario, y que la formalidad, la ocupación y la actividad encabezan la lista.

4. Modelos y validación en el futuro inmediato

4.1 Partición temporal

La pregunta es si los determinantes sirven para predecir el futuro, por eso los datos se separan **por tiempo** y no al azar: entrenamiento 1T2024-2T2025 (6 trimestres), validación 3T-4T2025 (para comparar modelos, elegir variables y calibrar las bandas) y prueba 1T2026 (evaluación final con datos que ningún modelo vio). Una partición al azar pondría a la misma persona en entrenamiento y en prueba, porque la EPH entrevista a cada hogar hasta cuatro veces, y el resultado sería optimista. Por eso se informa también el resultado para las mujeres "nuevas" del 1T2026.

4.2 Comparación de modelos

Se compararon seis modelos, desde el más interpretable hasta el más flexible, con métricas ponderadas por el factor de expansión de la encuesta y registro de cada experimento en MLflow:




Figura 3. R² en el conjunto de validación (izquierda) y al predecir cada trimestre con todos los anteriores (derecha).

- **Regresión lineal (ecuación de Mincer):** la referencia de la economía laboral, interpretable a través de sus coeficientes.
- **Ridge y Lasso:** regularización; Lasso además anula las variables que no aportan.

- **Árbol, Random Forest y LightGBM:** modelos no lineales que captan interacciones (por ejemplo, que el premio a la educación sea mayor en las grandes ciudades).

LightGBM es el mejor en validación ($R^2 = 0,52$), pero la ventaja sobre la regresión lineal es de solo 3-4 centésimas: la relación entre las características y el salario es casi lineal en logaritmos, como supone la ecuación de Mincer. Eso es una buena noticia para un producto: el modelo más preciso y el más explicable **cuentan la misma historia**. Una combinación de modelos (stacking) no mejoró el resultado y se descartó.

4.3 Selección de variables y optimización

Con dos criterios complementarios, los coeficientes de Lasso y la importancia por permutación en validación, se seleccionaron **26 de 105 variables**. El modelo reducido pierde apenas una centésima de R^2 y es mucho más fácil de aplicar: una empresa no necesita recolectar decenas de datos de cada empleada. Los hiperparámetros de LightGBM se eligieron con búsqueda en grilla y validación cruzada de 5 pliegues agrupada por hogar: R^2 medio de 0,537 (desvío 0,012) frente a 0,509 de la regresión lineal, con la misma estabilidad entre pliegues.

4.4 ¿Predice el futuro? Evaluación en el 1T2026 y estabilidad

Prueba	LightGBM	Regresión lineal	Lectura
R^2 en el 1T2026 (todas)	0,44	0,40	Explica casi la mitad de la variabilidad del salario relativo en un trimestre nuevo
R^2 en el 1T2026 (mujeres nuevas)	0,40	0,37	No depende de recordar a las encuestadas del panel
Origen móvil (1T2025-1T2026)	0,44 a 0,55	0,40 a 0,52	Siempre por encima de la regresión lineal
PSI máximo (composición)	0,039		Estable (umbral de alerta: 0,10)
Prueba de Wald 2024 vs. 2025	$F = 44, p < 0,001$		Cambian los 'precios': la prima del registro cae del 34% al 19%

Tabla 3. Validación fuera de tiempo y monitoreo de la estabilidad (detalle en el Anexo B).

Idea clave para el negocio

El modelo sirve para predecir a un año con la precisión habitual en ecuaciones salariales basadas en encuestas, que no miden la habilidad, el desempeño ni la empresa concreta. El mercado cambia más en sus 'precios' que en su composición: la herramienta debe reentrenarse cada trimestre, usando el PSI y la cobertura de las bandas como alertas.

4.5 Qué significa esta precisión para el negocio

Un R^2 de 0,44 puede parecer bajo, pero es alto para una ecuación salarial construida con una encuesta de hogares: la EPH no mide la habilidad, el desempeño, la negociación individual ni la empresa concreta, que explican buena parte del salario de cada persona. En la práctica, el error absoluto medio en el 1T2026 (0,34 en logaritmos) significa que el salario de una persona puede estar, típicamente, entre un 30% por debajo y un 40% por encima del predicho. Por eso la herramienta no devuelve un número, sino una **banda** (sección 9), y por eso su uso más sólido es **agregado**: al auditar una nómina, los errores individuales se compensan y lo que queda es el desvío sistemático de la empresa frente al mercado.

Cómo leer las medidas del trabajo

R²: proporción de las diferencias salariales que el modelo explica (0 = nada, 1 = todo).

SHAP: cuánto aporta cada variable a cada predicción; su promedio ordena los factores por importancia.

PSI: mide si cambió el tipo de personas encuestadas; por encima de 0,10 hay que revisar el modelo.

Banda del 90%: rango que debería contener el salario real de 9 de cada 10 personas con ese perfil.

Welfare ratio: cuántas canastas básicas de una familia tipo compra un salario a jornada completa (1 = justo alcanza).

5. ¿Qué determina el salario de las mujeres?

5.1 El peso de cada factor

Los valores SHAP reparten cada predicción de LightGBM entre las variables. Su promedio ordena los determinantes por **peso explicativo** y, agrupados por bloque, distinguen lo que puede modificar la persona, la empresa o la política pública.



Figura 4. Determinantes con más peso (SHAP, 1T2026) y reparto entre factores accionables y estructurales.

Los determinantes principales son el **aglomerado** (12% de la importancia), el **registro del empleo** (descuento jubilatorio y comprobante de pago, 20% entre ambos), la **jornada** (10%), los **años de educación** (10%) y la **actividad y la ocupación** del puesto (16%). En conjunto, el 63% del peso corresponde a factores sobre los que pueden actuar las empresas y la política laboral, el 14% a la propia persona y el 23% a factores estructurales.

Bloque de variables	Ejemplos	Quién puede actuar	% del peso
Condiciones de trabajo	Registro, comprobante de pago, jornada, intensidad, plan social	Empresa y política laboral	38%
Ocupación y empresa	Actividad, ocupación, calificación, tamaño, nivel del Estado	Empresa	25%
Capital humano	Educación, experiencia, antigüedad	La persona (con apoyo de la política educativa)	14%
Territorio	Agglomerado urbano	Estructural (política regional)	12%
Hogar, vivienda y estrategias del hogar	Parentesco, hijos, servicio doméstico, vivienda, préstamos	Estructural (política social y de cuidados)	11%

Tabla 4. Bloques de determinantes, según quién puede modificarlos (SHAP, 1T2026).

5.2 Cuánto vale cada factor: la ecuación de Mincer

La regresión lineal con las 26 variables ($R^2 = 0,50$) traduce los factores a efectos porcentuales sobre el salario por hora, con los demás constantes:

Factor	Efecto sobre el salario por hora	Comentario
Año adicional de educación	+3,4%	+8,6% sin controlar por ocupación y actividad: parte del retorno pasa por el puesto al que se accede
Empleo registrado	+25%	+52% en la ecuación clásica; cayó del 34% al 19% entre 2024 y 2025
Tramo de antigüedad	+3,3%	La experiencia en la empresa pesa más que la experiencia general (+0,7% por año)
Jornada parcial	+23%	Se concentra en docencia y salud, con pago por hora alto
Cobra un plan social por el trabajo	-31%	Marca de empleos precarios

Tabla 5. Efectos seleccionados de la ecuación de Mincer ampliada (errores agrupados por hogar; todos significativos al 1%).

5.3 Hijos y cuidados: el costo no está en el precio de la hora

Llama la atención que los hijos casi no pesen en el modelo. Eso no significa que no importen: su costo aparece en otro lugar.




Figura 5. Ocupación de las mujeres de 18 a 60 años según hijos pequeños (izquierda) y efecto del hogar sobre las asalariadas, a igual educación y ciudad (derecha).

- **Acceso al empleo:** el 64% de las mujeres sin hijos pequeños está ocupada, frente al 48% de las que tienen dos o más. A igual edad y educación, cada hijo de 0 a 5 años reduce 6 puntos la probabilidad de estar ocupada, sobre todo entre las menos educadas.
- **Horas:** hacerse cargo de las tareas de la casa reduce un 12% las horas de las asalariadas, y eso se traslada casi completo al salario mensual.
- **Precio de la hora:** las madres que trabajan no cobran menos por hora. Las más afectadas dejan de trabajar y no están en la muestra de salarios (sesgo de selección).

El modelo de Heckman corrige ese sesgo: el retorno de la educación sube del 10% al 13% por año y las mujeres que hoy no trabajan tendrían un salario por hora un 29% menor que las asalariadas (Anexo C). **Implicancia:** las políticas de cuidado actúan sobre la participación y las horas, y deben combinarse con formación para que las mujeres que se incorporen lo hagan con buenos salarios.

6. Territorio, recursos naturales y poder de compra

6.1 ¿Cuánto de la diferencia entre ciudades es costo de vida?

El aglomerado es el determinante con más peso. Para interpretarlo se comparan tres medidas para cada una de las 32 ciudades de la EPH: la prima **bruta** (diferencia salarial con el promedio del país), la prima **a igual perfil** (el coeficiente del aglomerado en la ecuación de Mincer) y la prima

real (la anterior descontando el costo de la Canasta Básica Total de la región, que el INDEC valoriza cada mes).




Figura 6. Prima salarial de cada ciudad a igual perfil, en pesos (arena) y descontando la canasta regional (azul).

El resultado cambia la lectura habitual del mapa salarial argentino. A igual perfil, la Patagonia paga un 22% más que el promedio y el Noreste un 17% menos: casi 40 puntos entre regiones. Pero la canasta patagónica cuesta un 17% más que la del Gran Buenos Aires y la del Noroeste un 20% menos; **descontando el costo de vida, la distancia entre regiones cae a 9 puntos**. Las diferencias reales que persisten son entre ciudades: la Ciudad de Buenos Aires (+10%), Neuquén (+9%) y Santa Rosa (+9%) pagan más de lo que cuesta vivir en ellas; San Juan (−15%), Concordia (−10%) y Mendoza (−9%), menos. Para una empresa con sucursales, la prima real es la referencia adecuada para fijar adicionales por zona.

6.2 ¿Llega la riqueza de los recursos naturales al salario de las mujeres?

Polo	Ciudades	% de asalariadas en el sector	Prima a igual perfil	Prima real
Hidrocarburos	Neuquén-Plottier (Vaca Muerta), Comodoro Rivadavia	4,5%	+26%	+5,5%
Minería (litio, cobre, oro)	Catamarca, Salta, Jujuy, San Juan, Río Gallegos	0,6%	−12%	0%
Resto del país	25 aglomerados	0,1%	−2%	−0,5%

Tabla 6. Polos energéticos y mineros.

El empleo femenino directo en estos sectores es pequeño: el beneficio, si llega, lo hace a través del mercado de trabajo local (comercio, salud, educación, servicios). Las ciudades petroleras ya lo muestran: pagan un 5,5% más en términos reales. Las mineras, todavía no. Como escenario, no como pronóstico: si alcanzaran la prima real de los polos petroleros, la asalariada mediana de esas ciudades ganaría un 5% más, unos \$43.000 por mes a jornada completa (1T2026). La herramienta permite seguir esta prima trimestre a trimestre.

6.3 ¿Alcanza el salario? El welfare ratio de Allen

Siguiendo a Allen (2001), el *welfare ratio* compara el salario a jornada completa con el costo de una canasta de necesidades básicas para una familia, valorizada a precios locales. Se usa la canasta oficial argentina y el hogar tipo del INDEC (pareja con dos hijos, 3,09 adultos equivalentes, casi igual a la familia de Allen):

$$\text{welfare ratio} = \text{salario horario} \times 172 \text{ horas} / (\text{Canasta Básica Total regional} \times 3,09)$$

No es lo mismo que expresar el salario en paridad de poder adquisitivo: la PPA convierte monedas con un índice de todo el consumo del país, mientras que el *welfare ratio* compara con una canasta básica de cada región y cada mes. Por eso recupera el nivel real del salario que la variable objetivo relativa neutraliza y responde una pregunta concreta de bienestar.




Figura 7. Welfare ratio mediano por trimestre (izquierda) y de las mujeres según nivel educativo (derecha).

El poder de compra se recuperó con fuerza desde el piso de comienzos de 2024 (0,51), pero **el salario mediano de una asalariada a jornada completa cubre solo tres cuartos de la canasta de una familia tipo** (0,75 en el 1T2026). Solo con título superior la mediana la supera (1,15); entre 8 y 9 de cada 10 asalariadas sin estudios superiores no alcanzarían a sostener a una familia fuera de la pobreza con su salario. El simulador de la aplicación informa este indicador para cualquier perfil: es un piso de referencia de "salario adecuado" que ningún cuadro publicado ofrece.

7. Brecha de género y transparencia retributiva

La Directiva (UE) 2023/970 obliga a las empresas europeas a justificar las brechas salariales de género iguales o superiores al **5%** en una misma categoría de trabajadores. Argentina no tiene una norma equivalente, pero la misma lógica puede aplicarse con los datos de la EPH: un modelo entrenado solo con varones indica cuánto cobraría cada mujer si su perfil se pagara como el de un varón; la diferencia con su salario real es la brecha **no explicada**.




Figura 8. Brecha no explicada por grupo de trabajadores frente al umbral de la Directiva.

La brecha observada es pequeña (4,8%), pero engaña: las asalariadas tienen en promedio **mejores** características que los varones (sobre todo más educación), así que la brecha a igual perfil es mayor, un 6,4%, por encima del umbral. Se concentra en el sector privado de mercado (comercio, industria y servicios profesionales, 13-15%), en la salud (10%) y en las ocupaciones operativas (12%); en el servicio doméstico, un empleo casi exclusivamente femenino, no existe. La brecha no explicada no prueba discriminación (puede reflejar factores no medidos), pero es exactamente la magnitud que una auditoría debe revisar.

Grupo de asalariadas	Brecha observada	Explicada por el perfil	No explicada	Mujeres encuestadas
Total	4,8%	-1,6%	6,4%	46.000
Sector privado	10,3%	4,4%	5,6%	29.190
Sector estatal	-0,7%	-8,0%	8,0%	15.544
Comercio	12,4%	-1,3%	13,8%	5.715
Industria	13,3%	-0,5%	13,8%	1.850
Salud y servicios sociales	13,5%	3,1%	10,0%	5.266
Enseñanza	0,7%	-2,9%	3,8%	7.173
Ocupaciones operativas	2,8%	-8,0%	11,7%	17.996
Servicio doméstico	-8,2%	0,3%	-8,5%	9.278

Tabla 7. Descomposición de la brecha de género por grupo (salario por hora, 2024-2026). Una brecha explicada negativa indica que las mujeres tienen mejor perfil que los varones del grupo.

El método es una versión flexible de la descomposición de Oaxaca-Blinder: en lugar de una regresión lineal, el contrafactual lo calcula LightGBM, que capta interacciones entre educación, ocupación y territorio. Para una empresa, la lectura práctica es directa: **los grupos con brecha no explicada superior al 5% son los que la Directiva obligaría a justificar**, y la pestaña de auditoría de la aplicación hace el mismo cálculo con su propia nómina.

8. Argentina frente a Brasil y España

Para distinguir lo propio del mercado argentino de lo general, el análisis se repitió con **las mismas 13 variables** y la misma variable objetivo relativa en la PNAD Continua de Brasil (630.000 registros de mujeres) y la Encuesta de Condiciones de Vida de España (20.000). Se comparan estructuras, no niveles en monedas distintas; los niveles se comparan al final con la paridad de poder adquisitivo.

La comparación exigió **armonizar** tres encuestas construidas con criterios distintos: la EPH pregunta el salario mensual neto del mes anterior, la PNAD el salario habitual del mes y la ECV el

ingreso neto anual del año anterior, que se divide por los meses y las horas trabajadas. La educación se llevó a años de estudio y la ocupación y la rama, a las clasificaciones internacionales (CIUO-08 y CIIU). Las 13 variables comunes cubren el capital humano, las condiciones de trabajo, la ocupación y la empresa, el hogar y el territorio (detalle en el Anexo D).




Figura 9. Efecto de cada factor sobre el salario por hora de las mujeres (izquierda) y poder de compra de una hora de trabajo (derecha).

Indicador	Argentina	Brasil	España
Bloque con más peso (SHAP)	Condiciones de trabajo (44%)	Capital humano (39%)	Ocupación y empresa (43%)
R² con las 13 variables comunes	0,35	0,53	0,32
Brecha observada / no explicada	4% / 6%	6% / 15%	7% / 11%
Welfare ratio internacional (línea de 8,30 USD PPA, familia de 3)	1,2	0,8	3,2

Tabla 8. Principales resultados comparados (mujeres asalariadas).

Efecto sobre el salario por hora (%)	Argentina	Brasil	España
Año adicional de educación	+5,1	+5,8	+3,9
Año de experiencia (inicial)	+1,1	+1,3	+2,2
Ocupación calificada (vs. media)	+20,5	+65,3	+33,6
Ocupación no calificada (vs. media)	-12,5	-3,6	-12,1
Empleo registrado / contrato escrito	+43,6	+34,2	+16,0
Contrato temporal	-12,5	-15,8	-9,4
Jornada parcial	+27,2	+28,5	+8,1
Gran ciudad	+9,2	+8,8	+6,6
En pareja	+9,2	+9,3	+2,5
Cada menor de 6 años en el hogar	+1,2	+3,5	-4,9
Cada otro ocupado del hogar	-4,2	-1,8	-1,3

Tabla 9. Ecuación de Mincer común (mujeres asalariadas; R² = 0,40 en Argentina, 0,47 en Brasil y 0,30 en España).

- **Los mismos factores, distinta intensidad.** La educación suma un 4-6% por año en los tres países. La escala por calificación es mucho más empinada en Brasil (+65% para una ocupación calificada) que en España (+34%) y Argentina (+21%).
- **La informalidad pesa más en América Latina:** el empleo registrado vale un 44% en Argentina y un 34% en Brasil; en España, el contrato escrito frente al verbal, un 16%.
- **Tres mercados, tres lógicas:** en Argentina la diferencia salarial entre mujeres está sobre todo en cómo están contratadas; en Brasil, en cuánto estudiaron; en España, en qué puesto ocupan.

- **La brecha a igual perfil supera el 5% en los tres países;** en España, donde la Directiva ya rige, la duplica.
- **Poder de compra:** una hora de la asalariada mediana vale 6,3 dólares internacionales en Argentina, 4,2 en Brasil y 16,8 en España. Con la línea de pobreza de 8,30 dólares diarios del Banco Mundial para una familia de tres, el salario mediano cubre 1,2 veces esa línea en Argentina, 0,8 en Brasil y 3,2 en España.
- **Los hijos pequeños solo penalizan en España** (-4,9% por hora por cada menor de 6 años); en Argentina y Brasil el costo de los cuidados aparece, como se vio en la sección 5.3, en el acceso al empleo y en las horas.

La Encuesta de Estructura Salarial (nóminas de empresas) confirma los efectos españoles de educación y calificación; los de contrato temporal y jornada parcial difieren entre fuentes y se leen con cautela (Anexo D).

9. Del modelo a la herramienta

9.1 Bandas salariales y aplicación

La Guía del máster valora que el modelo pueda productivizarse, es decir, que reciba valores nuevos y devuelva una predicción. El trabajo lo hace en dos pasos. Primero, las **bandas salariales**: una empresa no necesita un número, necesita un rango. Con regresión cuantílica conformal (Romano et al., 2019) cada perfil recibe una banda que debería contener el salario real 9 de cada 10 veces; en el 1T2026 la cobertura real fue del 85%, algo menos que el objetivo porque el mercado cambió, lo que funciona como alerta de recalibración. Segundo, una **aplicación web** publicada en Streamlit Community Cloud, pensada para una persona de recursos humanos o un funcionario:

Pestaña	Pregunta que responde
¿Cuánto debería cobrar?	Salario de mercado y banda del 90% para un perfil, explicación de cada factor y welfare ratio
Auditoría de nómina	Quiénes cobran por debajo del mercado, cuánto costaría corregirlo y brecha de género a igual perfil frente al 5%
Territorio y recursos naturales	Prima nominal y real de cada ciudad y de los polos energéticos y mineros
Hogar y cuidados	Cómo afectan los hijos el empleo, las horas y el salario
Argentina, Brasil y España	Qué factores premia cada mercado y cuánto vale el salario en cada país

Tabla 10. Pestañas de la aplicación (*tfm-olguin-patricia.streamlit.app*).



Figura 10. Simulador: salario esperado, banda y welfare ratio para un perfil.

Un ejemplo: ¿cuánto debería cobrar esta trabajadora?

Una asalariada del Gran Buenos Aires con secundaria completa (12 años de estudio), 20 años de experiencia, más de cinco años en su empleo, jornada parcial y empleo registrado.

Salario de mercado (1T2026): \$4.962 por hora; banda del 90%: entre \$2.653 y \$9.526.

A jornada completa: \$853.459 por mes, que cubre 0,63 veces la canasta básica de una familia tipo de su región.

Lectura para recursos humanos: si su empresa le paga menos de \$2.653 por hora, está fuera de mercado; si le paga la mediana, aun así su salario no alcanza para sostener a una familia.

9.2 Un caso de uso: la auditoría de una nómina

Con una nómina de demostración de 300 personas del sector salud (simulada con registros de la EPH; no corresponde a ninguna empresa), la aplicación identifica en segundos que el 5% cobra por debajo de la banda de mercado, estima el costo mensual de corregirlo y calcula una brecha de género a igual perfil del 8%, por encima del umbral europeo. Ninguna empresa necesita compartir sus datos: el modelo se aplica a su propia nómina anonimizada.




Figura 11. Auditoría de nómina con la lógica de la Directiva (UE) 2023/970.

9.3 Arquitectura y puesta en producción

El modelo no se reentrena en la aplicación: el notebook lo entrena, lo valida y lo publica en el repositorio, y la aplicación solo lo aplica, como ocurriría en una empresa. Todas las piezas son gratuitas y reproducibles:




Figura 12. Arquitectura del producto y ciclo de actualización trimestral.

Riesgo	Indicador de control	Umbral	Acción
Cambia el tipo de personas encuestadas	PSI por variable	> 0,10	Revisar la depuración y reentrenar
Cambian los precios del mercado	Prueba de Wald entre años; R² en la nueva onda	p < 0,05; caída > 5 puntos	Reentrenar con la ventana más reciente
Las bandas dejan de cubrir	Cobertura real de la banda del 90%	< 85%	Recalibrar el ajuste conformal
Cambia el costo de vida	Canasta Básica Total regional	Cada mes (INDEC)	Actualizar el welfare ratio y la prima real
Uso indebido de los resultados	Revisión de la auditoría por personas	Siempre	La brecha no explicada señala dónde mirar; no prueba discriminación

Tabla 11. Plan de monitoreo del modelo en producción.

9.4 Quién puede usarla y qué valor aporta

Usuario	Uso	Valor
Área de recursos humanos de una empresa	Fijar salarios de ingreso, revisar la nómina, adicionales por zona	Pagar según el mercado, retener talento y anticipar la exigencia de transparencia retributiva
Consultoras de compensaciones	Referencia de mercado por perfil y región, con banda	Complementa las encuestas salariales privadas, caras y centradas en grandes empresas
Ministerio de Trabajo y organismos provinciales	Monitorear el salario real y la brecha de las mujeres por región y sector	Información trimestral que los cuadros publicados no ofrecen
Organismos internacionales (OIT, CEPAL, BID)	Comparar estructuras salariales entre países	Metodología replicable con encuestas de hogares de otros países

Tabla 12. Usuarios potenciales de la herramienta.

Ninguno de estos usos requiere que la empresa comparta datos: la aplicación funciona con la nómina anonimizada que carga la propia usuaria y no la guarda. El costo de mantenimiento es bajo (una ejecución trimestral del notebook) y el proceso es escalable: la misma estructura puede entrenarse con los varones, con todos los asalariados o con los microdatos de otro país.

10. Conclusiones, limitaciones y líneas futuras

10.1 Conclusiones

El trabajo se propuso determinar los factores que influyen en el salario de las mujeres asalariadas en Argentina y predecir sus valores en el corto plazo, compararlos con Brasil y España y convertir el resultado en una herramienta de referencia salarial. Sus conclusiones principales son:

- 1. El empleo pesa más que la formación.** Las condiciones del puesto (registro, jornada, ocupación y actividad) concentran el 63% de lo que explica el modelo; la educación y la experiencia, el 14%, y los factores estructurales, el 23%. A igualdad del resto, cada año de educación suma un 3,4% al salario por hora y el empleo registrado, un 25%.
- 2. Los cuidados se pagan en empleo y en horas, no en el precio de la hora:** cada hijo de 0 a 5 años reduce 6,2 puntos la probabilidad de estar ocupada. Corregido el sesgo de selección, el retorno de la educación sube del 10% al 13% por año.
- 3. El territorio pesa menos de lo que parece.** Descontando el costo de vida, la distancia entre regiones se reduce de 39 a 9 puntos. Los polos petroleros ya elevan el salario real de las mujeres (+5,5%); los mineros, todavía no.
- 4. El salario mediano no alcanza para sostener a una familia.** Cubre tres cuartos de la canasta básica de una familia tipo, por lo que hacen falta varios ingresos en el hogar para superar la línea de pobreza.
- 5. La estructura predice a un año, pero sus precios cambian.** El modelo explica el 44% del salario relativo de un trimestre nuevo; la composición de la población es estable (PSI de 0,039), pero la prima del registro se redujo casi a la mitad en un año. Hay que reentrenar cada trimestre.
- 6. La brecha a igual perfil supera el 5%.** Es del 6,4%, frente a una brecha observada del 4,8%, y se concentra en el sector privado de mercado y en las ocupaciones operativas y profesionales: indica dónde focalizar las auditorías de nómina.
- 7. La herramienta es utilizable.** Las bandas del 90% alcanzaron una cobertura real del 85% en el 1T2026, y la aplicación permite estimar el salario de un perfil, auditar una nómina y monitorear el mercado de trabajo femenino.
- 8. Los mismos factores, con distinta intensidad.** La educación rinde entre un 4% y un 6% por año en los tres países; la calificación pesa mucho más en Brasil, la experiencia en España y la informalidad en América Latina. La brecha a igual perfil supera el 5% en los tres.

10.2 Recomendaciones

Destinatario	Recomendación	Evidencia del trabajo
La trabajadora	Completar estudios superiores y buscar empleo registrado: son los factores individuales con mayor retorno	Título superior: welfare ratio 1,15; registro: +25% a igual perfil; educación: +3-5% por año
Las empresas	Usar bandas de mercado para fijar salarios, auditar la brecha por categoría y fijar adicionales por zona según la prima real	Brecha no explicada 13-15% en comercio, industria y servicios profesionales; prima real entre ciudades de -15% a +10%
La política laboral	Reducir la informalidad y vigilar la caída de la prima del registro	El registro es el factor accionable de más peso y su prima cayó del 34% al 19% en un año
La política de cuidados	Ampliar la oferta de cuidado infantil, sobre todo para las mujeres menos educadas	Cada hijo de 0 a 5 años reduce 6 puntos la probabilidad de estar ocupada
La política regional	Promover que los proyectos mineros generen empleo local de calidad, como ocurrió en Vaca Muerta	Hidrocarburos: +5,5% real; minería: 0%

Tabla 13. Recomendaciones según quién puede actuar.

10.3 Mejoras que ofrece el trabajo

Frente a un análisis descriptivo de la EPH o a un AutoML, el trabajo aporta variables que la encuesta no pregunta, una validación genuina en el futuro, interpretación económica de cada resultado, medidas reales del territorio y del bienestar, una comparación internacional homogénea y un producto con bandas de garantía estadística que puede usarse mañana en una empresa o en un organismo público.

10.4 Limitaciones

Los salarios son declarados en una encuesta de hogares urbana; el período es corto (nueve trimestres) y de fuerte cambio macroeconómico; los efectos son asociaciones, no efectos causales; la corrección de Heckman depende de sus restricciones de exclusión; la canasta regional refleja el consumo de los hogares de ingresos bajos y medios; y las encuestas de los tres países miden el salario de forma distinta (neto, bruto, anual).

10.5 Líneas futuras

- Extender el análisis a nuevas ondas de la EPH para seguir los cambios en los determinantes y en el welfare ratio.
- Seguir trimestre a trimestre la prima de los polos mineros para detectar si la expansión del litio y el cobre llega a los salarios.
- Incorporar registros administrativos (SIPA) para medir el efecto de la empresa concreta y estimar otros factores, como el desempeño personal.
- Automatizar la actualización trimestral del modelo y de la aplicación.

Bibliografía

- Allen, R. C. (2001). The Great Divergence in European Wages and Prices from the Middle Ages to the First World War. *Explorations in Economic History*, 38(4), 411-447.
- Arroyo Abad, L., Davies, E. y van Zanden, J. L. (2012). Between conquest and independence: Real wages and demographic change in Spanish America, 1530-1820. *Explorations in Economic History*, 49(2), 149-166.
- Blau, F. D. y Kahn, L. M. (2017). The Gender Wage Gap: Extent, Trends, and Explanations. *Journal of Economic Literature*, 55(3), 789-865.
- Heckman, J. J. (1979). Sample Selection Bias as a Specification Error. *Econometrica*, 47(1), 153-161.
- INDEC, IBGE e INE (2022-2026). Microdatos de la EPH, la PNAD Contínua, la ECV y la EES; Canasta Básica Total e IPC (INDEC).
- Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*.
- Kleven, H., Landais, C. y Søgaard, J. E. (2019). Children and Gender Inequality: Evidence from Denmark. *American Economic Journal: Applied Economics*, 11(4), 181-209.
- Lundberg, S. y Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*.
- Mincer, J. (1974). Schooling, Experience, and Earnings. National Bureau of Economic Research.
- Mullainathan, S. y Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *Journal of Economic Perspectives*, 31(2), 87-106.
- Olguín, P. (2025). Entre el bienestar y la subsistencia. Salarios de varones y mujeres en Mendoza en el siglo XX. XXIX Jornadas de Historia Económica, AAHE y Universidad Nacional de Jujuy, San Salvador de Jujuy, septiembre de 2025.
- Olguín, P. y Bragoni, B. (2020). Salarios reales y subsistencia de los trabajadores de Mendoza durante la gran expansión (Argentina, 1890-1914). *Revista de Historia Económica - Journal of Iberian and Latin American Economic History*, 1-28. doi:10.1017/S0212610920000051.
- Olguín, P. y Bragoni, B. (2023). Salarios de mujeres e ingreso familiar de subsistencia en Mendoza (Argentina) a principios del siglo XX. *Investigaciones de Historia Económica*. <https://doi.org/10.33231/j.ihe.2023.04.001>.
- Olguín, P. y Bragoni, B. (2025). Convivir para subsistir: salarios reales de varones y mujeres en Mendoza (primera mitad del siglo XX). En D. Santilli (comp.), *La Argentina entre tres siglos. Precios, salarios y desigualdad en la larga duración (1776-1945)*. Buenos Aires: Prometeo.
- Olguín, P., Mahnic, P., Norton, A. y Gómez, F. (2026). Lo que muestran y lo que ocultan las estadísticas. Desempeño económico y desigualdad en Mendoza en el largo plazo, 1895-2023. XXIX Jornadas de Investigación, SIIP, Universidad Nacional de Cuyo, Mendoza, abril de 2026.
- Oaxaca, R. (1973). Male-Female Wage Differentials in Urban Labor Markets. *International Economic Review*, 14(3), 693-709.
- Romano, Y., Patterson, E. y Candès, E. (2019). Conformalized Quantile Regression. *Advances in Neural Information Processing Systems*.
- Unión Europea (2023). Directiva (UE) 2023/970 por la que se refuerza la aplicación del principio de igualdad de retribución entre hombres y mujeres.
- Banco Mundial (2025). World Development Indicators: PPP conversion factor, households final consumption (PA.NUS.PRVT.PP); líneas de pobreza internacionales.

Anexo A. Variables seleccionadas

Las 26 variables del modelo final, con su bloque temático, quién puede actuar sobre ellas y su peso en las predicciones del 1T2026 (SHAP). El diccionario completo de las 97 candidatas está en el repositorio (modelos/diccionario_variables.csv).

Variable	Bloque	Carácter	% importancia
Aglomerado urbano	Territorio	Estructural	12,1
Descuento jubilatorio (empleo registrado)	Condiciones de trabajo	Empresa y política	10,9
Jornada parcial (< 35 horas)	Condiciones de trabajo	Empresa y política	10,1
Años de educación	Capital humano	Persona	9,5
Comprobante de pago	Condiciones de trabajo	Empresa y política	9,0
Actividad del establecimiento (CAES, 2 dígitos)	Ocupación y empresa	Empresa	8,7
Carácter de la ocupación (CNO, 2 dígitos)	Ocupación y empresa	Empresa	7,0
Intensidad de la ocupación	Condiciones de trabajo	Empresa y política	6,0
Calificación de la ocupación	Ocupación y empresa	Empresa	4,3
Parentesco con el jefe/a de hogar	Hogar y cuidados	Estructural	4,3
Personas que trabajan en el establecimiento	Ocupación y empresa	Empresa	3,9
Antigüedad en el empleo (tramos)	Capital humano	Persona	2,3
Ambientes de la vivienda	Vivienda y hábitat	Estructural	1,7
Pidió préstamos a familiares o amigos	Estrategias del hogar	Estructural	1,5
Experiencia potencial (años)	Capital humano	Persona	1,4
Cobra un plan social por este trabajo	Condiciones de trabajo	Empresa y política	1,1
Nivel del Estado (nacional, provincial, municipal)	Ocupación y empresa	Empresa	1,0
El hogar tiene servicio doméstico	Hogar y cuidados	Estructural	0,9
Cubierta del techo	Vivienda y hábitat	Estructural	0,8
Vendió pertenencias	Estrategias del hogar	Estructural	0,8
Horas en otras ocupaciones	Condiciones de trabajo	Empresa y política	0,7
Le dan de comer en el trabajo	Condiciones de trabajo	Empresa y política	0,6
Estado civil	Hogar y cuidados	Estructural	0,5
Hijos propios menores de 18 años	Hogar y cuidados	Estructural	0,5
Experiencia potencial al cuadrado	Capital humano	Persona	0,3
Casas en que trabaja (servicio doméstico)	Ocupación y empresa	Empresa	0,1

Tabla A.1. Variables seleccionadas por importancia por permutación y Lasso.

Anexo B. Detalle de los modelos

Modelo	RMSE	MAE	R ²
Media (línea de base)	0,614	0,480	0,000
Árbol de decisión	0,476	0,366	0,400
Regresión lineal (MCO)	0,441	0,338	0,486
Ridge	0,441	0,338	0,486
Lasso	0,440	0,338	0,487
Random Forest	0,439	0,335	0,488
LightGBM	0,424	0,321	0,523
LightGBM (26 variables)	0,430	0,327	0,509
LightGBM optimizado (26 variables)	0,427	0,326	0,517

Tabla B.1. Métricas ponderadas en el conjunto de validación (3T-4T2025). RMSE y MAE en puntos de log-salario.

Elemento	Detalle
Hiperparámetros elegidos	num_leaves = 15, n_estimators = 300, learning_rate = 0,05, min_child_samples = 100 (GridSearchCV, GroupKFold de 5 pliegues por hogar)
Validación cruzada (R ² medio ± desvío)	LightGBM 0,537 ± 0,012 · regresión lineal 0,509 ± 0,013
Prueba 1T2026	LightGBM: RMSE 0,458, MAE 0,344, R ² 0,435 · mujeres nuevas: R ² 0,405
Ecuación de Mincer	Clásica (educación, experiencia, registro): R ² 0,33 · ampliada (26 variables, 143 efectos, 77 significativos): R ² 0,50 · VIF máximo 1,57
Prueba de Wald 2024 vs. 2025	F = 44,1, p < 0,001; registro 33,7% → 19,2% (p < 0,001); educación 3,5% → 3,0%, jornada parcial 21% → 24%, antigüedad 2,9% → 3,2% (no significativos)
Bandas conformales	Cuantiles 5 y 95 con LightGBM, ajuste conformal -0,021 con validación; cobertura en el 1T2026: 85,2% (empleo registrado 84%, no registrado 87%)

Tabla B.2. Optimización, prueba y monitoreo.

Anexo C. Hogar, cuidados y sesgo de selección

Efecto	Salario por hora	Horas semanales	Salario mensual
Cada hijo de 0 a 5 años	+6,8%	-2,8%	+3,8%
Cada hijo de 6 a 17 años	+2,1%	-5,9%	-4,0%
Realiza las tareas de la casa	-1,8% (n.s.)	-12,0%	-13,6%
Cada persona más por cuarto (hacinamiento)	-8,2%	-2,3%	-10,2%
Año de educación de la pareja	+2,4%	+1,9%	+4,3%

Tabla C.1. Canales del hogar (asalariadas, a igual educación, experiencia y aglomerado; n.s. = no significativo).

Modelo de Heckman en dos etapas: probit de la probabilidad de ser asalariada con todas las mujeres de 18 a 60 años (restricciones de exclusión: hijos por tramo de edad, convivir en pareja y pareja ocupada) y ecuación de salarios con el inverso del ratio de Mills. Resultados: lambda = 0,82 (p < 0,001), rho = 0,95; retorno de la educación 10,2% → 13,3% por año; experiencia inicial 2,5% → 5,7%. Salario potencial por hora respecto de las asalariadas: no ocupadas -29% (-33% con dos o más hijos pequeños); otras ocupadas -1%.

Anexo D. Preparación de las bases de Brasil y España

- **Brasil (PNAD Contínua):** archivos de ancho fijo leídos con DuckDB según el programa de lectura del IBGE; asalariados de 18 a 60 años con ingreso habitual (VD4016) y horas (V4039); registro = VD4012; temporal = V4025; calificación según gran grupo de la CIUO-08; rama según la CNAE.

- **España (ECV):** asalariados hoy (PL040A = 3) que lo fueron los 12 meses del año anterior (PL073 + PL074 = 12), porque el ingreso (PY010N) es del año anterior; en pareja: PB205 = 1; contrato (PL141): temporal = 11 o 12, contrato escrito = 11 o 21; educación según CINE-2011 (PE041).
- **Variable objetivo común:** logaritmo del salario horario sobre la mediana ponderada de cada país y período, tras recortar el 0,5% extremo.

Efecto sobre el salario por hora de las mujeres	ECV (hogares)	EES 2022 (nóminas)
Año adicional de educación	+4,3%	+4,2%
Ocupación calificada (vs. media)	+35,2%	+38,3%
Ocupación no calificada (vs. media)	-13,2%	-2,6%
Contrato temporal	-12,5%	-0,1%
Jornada parcial	+9,8%	-9,3%

Tabla D.1. Validación de la ECV con la Encuesta de Estructura Salarial.

Anexo E. Reproducibilidad y enlaces

Elemento	Ubicación
Repositorio	github.com/peolguin/TFM-Olguin-Patricia (notebook, funciones, aplicación, modelos, resumen y video)
Notebook exportado	notebook/TFM_salarios_mujeres_Argentina.html (versión HTML ejecutada, según la Guía)
Notebook en Colab	colab.research.google.com/github/peolguin/TFM-Olguin-Patricia/blob/main/notebook/TFM_salarios_mujeres_Argentina.ipynb
Aplicación	tfm-olguin-patricia.streamlit.app
Datos	Carpeta TFM de Google Drive, compartida con los tutores: https://drive.google.com/drive/folders/1z812oAmY-nK_2uj-UJn6aJZZK1XbdWo9 (abrir el enlace y agregar un acceso directo en Mi unidad)
Tiempo de ejecución	Unos 15 minutos (más 15 la primera vez, para preparar Brasil y España). No requiere clave de GitHub.
Librerías	pandas, numpy, scikit-learn, LightGBM, statsmodels, SHAP, MLflow, DuckDB, plotly, Streamlit

Tabla E.1. Cómo reproducir el trabajo.

Anexo F. Notebook ejecutado

A continuación se incluye el notebook completo ejecutado en Google Colab (secciones 1 a 12), con el código, los resultados y los comentarios de cada sección. La versión HTML, con los gráficos interactivos, está en el repositorio ([notebook/TFM_salarios_mujeres_Argentina.html](#)), y el notebook puede abrirse en Colab con el enlace del Anexo E.

Trabajo Fin de Máster de Patricia Olguín

Determinantes y predicción del salario de las mujeres asalariadas en Argentina (2024-2026)

Una comparación con Brasil y España y una herramienta de referencia salarial

Máster en Data Science, Big Data & Business Analytics · Universidad Complutense de Madrid

Pregunta central. ¿Qué factores influyen en el salario de las mujeres asalariadas en Argentina y permiten predecir sus valores en el corto plazo? ¿Constituyen una particularidad del caso argentino o están presentes también en otros países, como Brasil y España? ¿Es posible diseñar una aplicación que aporte una referencia salarial?

Aporte. Aprovecha los microdatos de la Encuesta Permanente de Hogares (EPH) calculada por el Instituto Nacional de Estadística y Censos (INDEC), a fin de obtener información de manera indirecta, porque los cuadros publicados no responden las siguientes preguntas:

- ¿cuánto paga el mercado por un perfil concreto, y con qué margen?
- ¿cuánto de la diferencia salarial entre ciudades desaparece al descontar el costo de vida?
- ¿llega la riqueza de Vaca Muerta y de la minería al salario de las mujeres?
- ¿alcanza el salario de una asalariada para sostener a una familia (*welfare ratio* de Allen)?
- ¿cuánto de la brecha de género no se explica por el perfil, y supera el umbral del 5% de la Directiva europea de transparencia retributiva?

Estructura. La **parte I** estudia a las asalariadas argentinas: construye la base, entrena y valida los modelos fuera de tiempo, interpreta los determinantes y los traduce en la herramienta. La **parte II** repite el análisis con las mismas 13 variables en Brasil y España para distinguir lo que es propio del mercado argentino de lo que es general.

Datos. EPH (bases de personas y hogares, 1T2024-1T2026), Canasta Básica Total regional e IPC del INDEC y paridad de poder adquisitivo del Banco Mundial; para la comparación, la PNAD Continua (IBGE, Brasil) y la Encuesta de Condiciones de Vida y la Encuesta de Estructura Salarial (INE, España). Todos los archivos se leen desde Google Drive.

Ejecución. menú *Entorno de ejecución*, opción *Ejecutar todas*. Unos 15 minutos; la primera vez, unos 15 minutos más para preparar las bases de Brasil y España, que quedan guardadas en Drive. No hace falta ninguna clave de GitHub.

Índice

Parte I. Argentina: determinantes del salario de las mujeres y herramienta de referencia

1. Preparación del entorno
2. Datos: de la encuesta a la base de estudio
3. Depuración de los datos
4. Exploración
5. Modelado predictivo
6. Evaluación en el futuro inmediato y estabilidad
7. ¿Qué determina el salario de las mujeres?
8. Territorio, recursos naturales y poder de compra
9. Brecha de género y transparencia retributiva
10. Del modelo al producto: bandas salariales y aplicación

Parte II. Argentina frente a Brasil y España

11. Perspectiva comparada: preparación de las bases, factores que premia cada mercado, brecha y poder de compra

Conclusiones

12. Conclusiones generales

PARTE I. ARGENTINA: DETERMINANTES DEL SALARIO DE LAS MUJERES Y HERRAMIENTA DE REFERENCIA

1. Preparación del entorno

1.1 Repositorio de GitHub

El notebook clona el repositorio del trabajo, que contiene el archivo de funciones (funciones_tfm.py) y la aplicación. Para **leerlo** no hace falta ninguna clave. Solo la autora, que guarda su token en los *Secretos* de Colab con el nombre GITHUB_TOKEN, sube los resultados a GitHub (secciones 10 y 11).

```
import os
import subprocess
import sys

USUARIO, REPO = "peolguin", "TFM-Olguin-Patricia"
EN_COLAB = "google.colab" in sys.modules
ruta_repo = f"/content/{REPO}" if EN_COLAB else
os.path.abspath(os.environ.get("TFM_REPO", "repo"))

# Token de GitHub: solo existe en la cuenta de la autora
token = None
if EN_COLAB:
```

```

try:
    from google.colab import userdata
    token = userdata.get("GITHUB_TOKEN")
except Exception:
    print("Sin token de GitHub: el notebook se ejecuta completo, pero no sube resultados al repositorio.")

def git(*args):
    """Ejecuta un comando de git dentro del repositorio."""
    resultado = subprocess.run(["git", *args], cwd=ruta_repo, capture_output=True, text=True)
    print(resultado.stdout.strip() or resultado.stderr.strip())

if EN_COLAB and not os.path.isdir(ruta_repo):
    url = f"https://{USUARIO}:{token}@github.com/{USUARIO}/{REPO}.git" if token else f"https://github.com/{USUARIO}/{REPO}.git"
    subprocess.run(["git", "clone", url, ruta_repo], check=True)
elif EN_COLAB:
    git("pull")

def guardar_en_github(mensaje):
    """Hace el commit de los resultados y los sube a GitHub (solo con el token de la autora)."""
    if EN_COLAB and token:
        git("config", "user.email", "patricia.elizabeth.olguin@gmail.com")
        git("config", "user.name", "Patricia Olguin")
        git("add", ".")
        git("commit", "-m", mensaje)
        git("push", "origin", "main")

os.makedirs(os.path.join(ruta_repo, "modelos"), exist_ok=True)
print("Repositorio listo en", ruta_repo)

```

Updating 03ed0f5..20c6c7e

Fast-forward

README.md		47	+++--
app/app.py		269	+++++-----
notebook/TFM_salarios_mujeres_Argentina.ipynb		276	+++++-----

3 files changed, 352 insertions(+), 240 deletions(-)

Repositorio listo en /content/TFM-Olguin-Patricia

1.2 Drive, librerías y funciones

Como en el módulo de Minería de datos, las funciones auxiliares están en un archivo aparte, funciones_tfm.py, que se importa al inicio.

```

if EN_COLAB:
    from google.colab import drive
    drive.mount("/content/drive")
    subprocess.run([sys.executable, "-m", "pip", "install", "-q", "mlflow", "shap", "missingno"])

sys.path.append(ruta_repo)
from funciones_tfm import *

```

```

import shutil
import warnings

import joblib
import lightgbm as lgb
import missingno as msno
import mlflow
import plotly.graph_objects as go
import statsmodels.formula.api as smf
from IPython.display import Markdown, display
from sklearn.ensemble import RandomForestRegressor
from sklearn.inspection import permutation_importance
from sklearn.linear_model import LassoCV, LinearRegression, RidgeCV
from sklearn.model_selection import GridSearchCV, GroupKFold, cross_val_score
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.tree import DecisionTreeRegressor

warnings.filterwarnings("ignore")
sns.set()
pd.set_option("display.max_columns", 60)
pd.set_option("display.width", 180)

```

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).

1.3 Archivos de datos

Todos los datos se descargan **una sola vez** de las fuentes oficiales y se guardan en Drive, en la carpeta MyDrive/TFM/ (quien evalúe el trabajo puede agregar a su Drive un acceso directo a la carpeta compartida por la autora):

Carpeta	Archivo	Fuente
datos_originales/	eph_{año}_trim{trimestre}_{pers hog}.csv (18 archivos)	INDEC, EPH continua, bases de usuarios
datos_originales/	canasta_basica_regional.csv	INDEC, Canasta Básica Total por región (informes de pobreza)
datos_originales/	ipc_indec.csv	INDEC, IPC nivel general nacional (series de tiempo)
datos_originales/	ppa_banco_mundial.csv	Banco Mundial, PPA del consumo de los hogares (PA.NUS.PRVT.PP)
datos_comparacion/pnadc/	PNADC_{trimestre}_{año}.zip (1T2024-2T2026) y Diccionario_e_input.zip	IBGE, PNAD Contínua trimestral
datos_comparacion/ecv/ y ees/	datos_2024.zip, datos_2025.zip; datos_2022.zip	INE, Encuesta de Condiciones de Vida y Encuesta de Estructura Salarial

Los microdatos de Brasil y España solo se leen la primera vez: la parte II guarda una base común reducida en datos_procesados/ y la reutiliza.

```

ruta_drive = os.environ.get("TFM_DRIVE", "/content/drive/MyDrive")
ruta_datos = os.path.join(ruta_drive, "TFM", "datos_originales")
ruta_salida = os.path.join(ruta_drive, "TFM", "datos_procesados")
os.makedirs(ruta_salida, exist_ok=True)

# Ondas de la EPH (año, trimestre). Para sumar una onda nueva alcanza con agregarla
aquí.
ondas = [(2024, 1), (2024, 2), (2024, 3), (2024, 4), (2025, 1), (2025, 2), (2025, 3),
(2025, 4), (2026, 1)]

```

```
def ruta_eph(ano, trimestre, tipo):
    return os.path.join(ruta_datos, f"eph_{ano}_trim{trimestre}_{tipo}.csv")

ARCHIVOS = ([ruta_eph(a, t, tipo) for a, t in ondas for tipo in ("pers", "hog")]
             + [os.path.join(ruta_datos, f) for f in ("canasta_basica_regional.csv",
"ipc_indec.csv", "ppa_banco_mundial.csv")])
faltan = [f for f in ARCHIVOS if not os.path.isfile(f)]
if faltan:
    raise FileNotFoundError("Faltan archivos en Drive:\n" + "\n".join(faltan))
ruta_comparacion = os.path.join(ruta_drive, "TFM", "datos_comparacion")
ruta_base_comun = os.path.join(ruta_salida, "base_comun_BR_ES.parquet")
ruta_validacion_ees = os.path.join(ruta_salida, "validacion_EES.csv")
HAY_COMPARACION = os.path.isfile(ruta_base_comun)
print(f"{len(ARCHIVOS)} archivos de la parte I disponibles | base común de Brasil y España: "
      f"'{ya preparada}' if HAY_COMPARACION else 'se prepara en la sección 11.1'")
```

21 archivos de la parte I disponibles | base común de Brasil y España: ya preparada

2. Datos: de la encuesta a la base de estudio

2.1 Lectura de las bases de personas y hogares

```
personas = {(a, t): leer_eph(ruta_eph(a, t, "pers")) for a, t in ondas}
hogares = {(a, t): leer_eph(ruta_eph(a, t, "hog")) for a, t in ondas}
clave_hogar = ["CODUSU", "NRO_HOGAR"]

# Tamaño de cada onda y controles de integridad
pd.DataFrame([{"onda": f"{t}T{a}", "personas": personas[(a, t)].shape[0], "columnas personas": personas[(a, t)].shape[1],
               "hogares": hogares[(a, t)].shape[0], "columnas hogares": hogares[(a, t)].shape[1],
               "duplicados": personas[(a, t)].duplicated(clave_hogar + ["COMPONENTE"]).sum(),
               "personas sin hogar": (~personas[(a, t)].set_index(clave_hogar).index.isin(hogares[(a, t)].set_index(clave_hogar).index)).sum()} for a, t in ondas])
```

	onda	personas	columnas personas	hogares	columnas hogares	duplicados	personas sin hogar
0	1T2024	46050	235	16104	98	0	0
1	2T2024	47151	235	16453	98	0	0
2	3T2024	47564	235	16650	98	0	0
3	4T2024	46860	235	16511	98	0	0
4	1T2025	45425	235	15984	98	0	0
5	2T2025	46086	235	16169	98	0	0
6	3T2025	44946	235	15860	98	0	0
7	4T2025	43703	235	15534	98	0	0
8	1T2026	43739	234	15447	98	0	0

Cada onda tiene unas 45.000 personas y 16.000 hogares, con 234 columnas en la base de personas y 98 en la de hogares. No hay registros duplicados y todas las personas tienen su hogar: las bases se pueden unir con seguridad.

2.2 Construcción de la base de estudio

Antes de filtrar usamos la base de personas **completa** (todos los miembros de cada hogar) para construir variables que la EPH no pregunta a la trabajadora (función `variables_del_hogar`):

- **Hijos propios:** la EPH solo registra el parentesco de cada miembro con el jefe o la jefa del hogar. Si la trabajadora es jefa o cónyuge, sus hijos son los miembros registrados como hijos; si es hija o nuera, se aproximan por los nietos del jefe.
- **Educación de la pareja, si está ocupada y clima educativo del hogar** (años de educación de los otros adultos, un proxy del origen social).
- **Composición del hogar:** menores, mayores y otros ocupados.

Luego nos quedamos con la **población de estudio**: asalariados ocupados de 18 a 60 años con salario ($P21 > 0$), ponderador de ingresos ($PONDIO > 0$) y horas válidas. Los varones se conservan solo para medir la brecha de género (sección 9). También guardamos a **todas** las mujeres de 18 a 60 años, trabajen o no (sección 7.3).

```
bases, poblacion = [], []
for a, t in ondas:
    base_onda, mujeres_onda = procesar_onda(personas[(a, t)], hogares[(a, t)], a, t,
clave_hogar)
    bases.append(base_onda)
    poblacion.append(mujeres_onda)
base = pd.concat(bases, ignore_index=True).drop(columns=["CAT_INAC"],
errors="ignore")
POBLACION_FEMENINA = pd.concat(poblacion, ignore_index=True)
del personas, hogares, bases
print(f"Base de estudio: {base.shape[0]:,} asalariados y {base.shape[1]} columnas")
base.groupby(["ANO4", "TRIMESTRE", "CH04"]).size().unstack().rename(columns={1:
"varones", 2: "mujeres"}).T
```

Base de estudio: 96,844 asalariados y 319 columnas

	ANO4				2024				2025	2026
TRIMESTRE	1	2	3	4	1	2	3	4	1	
CH04										
varones	5723	5980	5883	5926	5470	5822	5563	5373	5131	
mujeres	4941	5556	5474	5468	4644	5324	5054	5046	4466	

2.3 Variable objetivo


- **Salario horario** = $P21 / (PP3E_TOT \times 4,3 \text{ semanas})$. Usamos el salario *por hora* para comparar jornadas distintas: las mujeres trabajan más a tiempo parcial por las tareas de cuidado no remuneradas.
- **Relativo:** lo dividimos por la **mediana ponderada** del salario horario de todos los asalariados del trimestre. Así se neutralizan la inflación, la estacionalidad y la volatilidad macroeconómica sin necesidad de deflactar.
- **Variable objetivo:** $y = \log(\text{salario horario} / \text{mediana del trimestre})$. $y = 0$ es cobrar la mediana; $y = 0,10$, cobrar alrededor de un 10% más.

Antes de calcular la mediana eliminamos el 0,5% superior e inferior del salario horario de cada trimestre, que suelen ser errores de declaración.

```
base["periodo"] = base["AN04"] * 10 + base["TRIMESTRE"] # 20241 ... 20261
base["t"] = (base["AN04"] - 2024) * 4 + base["TRIMESTRE"] - 1 # 0 ... 8
base["id_hogar"] = base["CODUSU"] + "_" + base["NRO_HOGAR"].astype(str)
base["id_persona"] = base["id_hogar"] + "_" + base["COMPONENTE"].astype(str)

# Salario horario y recorte de valores extremos por trimestre
base["salario_horario"] = base["P21"] / (base["PP3E_TOT"] * 4.3)
limites = base.groupby("periodo")["salario_horario"].quantile([0.005, 0.995]).unstack()
base = base[base["salario_horario"].between(base["periodo"].map(limites[0.005]), base["periodo"].map(limites[0.995]))].reset_index(drop=True)

# Mediana ponderada de cada trimestre y variable objetivo
mediana_trimestre = base.groupby("periodo").apply(lambda g: mediana_ponderada(g["salario_horario"], g["PONDII0"]))
base["mediana_trimestre"] = base["periodo"].map(mediana_trimestre)
base["y"] = np.log(base["salario_horario"] / base["mediana_trimestre"])
es_mujer = base["CH04"] == 2
histogram_boxplot(base.loc[es_mujer, "y"], xlabel="y = log(salario horario / mediana del trimestre)",
                    title="Distribución de la variable objetivo (mujeres)",
                    pd.DataFrame({"mediana del salario horario ($)": mediana_trimestre.round(0),
                                "variación trimestral (%)": (100 * mediana_trimestre.pct_change()).round(1)}).T
```



Comentarios

La base de estudio reúne unos 97.000 registros de asalariados, 46.000 de ellos de mujeres (unas 5.000 por trimestre). La mediana nominal del salario horario se multiplicó por más de tres en el período, con subas trimestrales que bajaron del 52% al 3%. La variable objetivo relativa elimina ese efecto: lo que se modela es la **posición** de cada trabajadora en la distribución salarial de su trimestre. Su distribución es aproximadamente simétrica y centrada algo por debajo de 0 (las mujeres cobran por hora un poco menos que la mediana de todos los asalariados).

A partir de aquí las **decisiones** de depuración se toman solo con los datos de las mujeres; las transformaciones se aplican también a los varones.

3. Depuración de los datos

3.1 Selección inicial de variables (criterio conceptual)

De las más de 300 columnas excluimos, con un motivo explícito, las que no pueden usarse para explicar el salario:

Grupo excluido	Motivo
Identificación, control técnico y ponderadores	No describen a la persona
Definen la población o la variable objetivo	Son constantes tras el filtro, o construyen el salario horario
Ingresos que contienen el salario	Deciles e ingresos individuales y familiares: usarlos sería fuga de información
Montos de otros ingresos, texto libre	Son montos o descripciones abiertas; la información está en otras variables
Preguntas que no corresponden a asalariadas	Módulos de desocupados, inactivos e independientes

```
mujeres = base[es_mujer]
EXCLUSION = {
    "Identificación, control técnico y ponderadores": ["CODUSU", "NRO_HOGAR",
"COMPONENTE", "H15", "REALIZADA", "IMPUTA",
                                                    "AN04", "TRIMESTRE",
"PONDERA", "PONDII", "PONDIIH", "PONDIIIO"],
    "Definen la población o la variable objetivo": ["CH04", "ESTADO", "CAT_OCUP",
"P21", "PP3E_TOT"],
    "Ingresos que contienen el salario": [c for c in mujeres.columns if
re.search(r"DEC|^P47T$|^ITF$|^IPCF$|^PP08", c)],
    "Montos de otros ingresos, texto libre": ["TOT_P12", "T_VI", "PP06C", "PP06D",
"CH05", "CH15_COD", "CH16_COD"]
                                + [c for c in mujeres.columns if
re.fullmatch(r"V\d+(\d+)?A?M", c) or c.endswith("_ESP")],
    "Preguntas que no corresponden a asalariadas": [c for c in mujeres.columns if
re.match(r"PP0?(2|5|6|10|11)[A-Z_]", c)],
}
AUXILIARES = ["periodo", "t", "id_hogar", "id_persona", "salario_horario",
"mediana_trimestre", "y"]
CONSTRUIDAS_HOGAR = ["menores_6", "menores_18", "mayores_65", "ocupados_hogar",
"mujeres_adultas_hogar",
                    "hijos_propios_menores_6", "hijos_propios_menores_18",
"educ_pareja", "pareja_ocupada", "clima_educativo"]

# Tabla de decisiones: cada variable con su base de origen y el motivo de exclusión
motivo = {v: grupo for grupo, vs in EXCLUSION.items() for v in vs if v in
```

```

mujeres.columns}
diccionario = pd.DataFrame({"variable": [c for c in mujeres.columns if c not in
AUXILIARES]})
diccionario["base"] = np.where(diccionario.variable.isin(CONSTRUIDAS_HOGAR),
"Construida",

np.where(diccionario.variable.str.match(r"^(IV|II|V\d|IX|VII)"), "Hogares",
"Personas"))
diccionario["motivo de exclusión"] =
diccionario.variable.map(motivo).fillna("candidata")
candidatas = diccionario.loc[~diccionario.variable.isin(motivo), "variable"].tolist()
print(f"Variables: {len(diccionario)} | candidatas: {len(candidatas)}")
diccionario.groupby(["motivo de exclusión", "base"]).size().unstack(fill_value=0)

```

Variables: 319 | candidatas: 148

	base	Construida	Hogares	Personas
motivo de exclusión				
Definen la población o la variable objetivo		0	0	5
Identificación, control técnico y ponderadores		0	0	12
Ingresos que contienen el salario		0	0	44
Montos de otros ingresos, texto libre		0	27	7
Preguntas que no corresponden a asalariadas		0	0	76
candidata		10	69	69

3.2 Códigos "no sabe / no responde" y preguntas que no aplican

Según el diseño de registros, los códigos 9 y 99 son "no sabe / no responde" salvo en las variables donde son valores válidos (conteos, edad, aglomerado, techo de la vivienda). Los convertimos en nulos. Luego eliminamos las candidatas con más del 90% de sus valores en "no corresponde" (0) o nulos: son preguntas dirigidas a subgrupos muy pequeños.

```

df = base[candidatas + AUXILIARES + ["PONDII0", "CH04", "AN04", "TRIMESTRE",
"COMPONENTE", "PP3E_TOT"]].copy()
m = es_mujer # máscara de mujeres: las decisiones se toman con ellas

CONTEOS = ["CH06", "IV2", "II1", "II2", "II3_1", "II5_1", "II6_1", "IX_TOT",
"IX_MEN10", "IX_MAYEQ10", "PP03D",
"PP3F_TOT", "PP04B2", "PP04B3_MES", "PP04B3_ANO", "PP04B3_DIA"] +
CONSTRUIDAS_HOGAR
SIN_CODIGO_NSNR = CONTEOS + ["AGLOMERADO", "REGION", "IV4", "PP04B_COD", "PP04D_COD",
"VII1_1", "VII1_2", "VII2_1",
"VII2_2", "VII2_3", "VII2_4", "MAS_500", "CH03",
"PP04G"]
for col in candidatas:
    if col not in SIN_CODIGO_NSNR and pd.api.types.is_numeric_dtype(df[col]):
        df[col] = df[col].replace(9 if df[col].max() <= 9 else 99, np.nan)
df["CH14"] = df["CH14"].replace([98, 99], np.nan)
df["PP3F_TOT"] = df["PP3F_TOT"].replace(999, np.nan)
for col in ["IV2", "II1", "II2", "IX_TOT"]:
    df[col] = df[col].replace(99, np.nan)

no_aplica = pd.Series({c: ((df.loc[m, c] == 0) | df.loc[m, c].isna()).mean() for c in
candidatas
                        if pd.api.types.is_numeric_dtype(df[c]) and c not in CONTEOS})
candidatas = [c for c in candidatas if c not in no_aplica[no_aplica > 0.90].index]

```

```
print(f"Eliminadas por no aplicar a las asalariadas: {(no_aplica > 0.90).sum()} |  
candidatas: {len(candidatas)}")
```

Eliminadas por no aplicar a las asalariadas: 8 | candidatas: 140

3.3 Ingeniería de variables

Con la función `crear_variables` construimos variables más informativas y reducimos la cardinalidad de los códigos largos: años de educación y **experiencia potencial** de Mincer (edad – educación – 6); carácter, jerarquía, tecnología y calificación de la ocupación (CNO-2001); actividad a 2 dígitos y rama (CAES-Mercosur); tamaño del establecimiento; antigüedad; jornada parcial (< 35 horas); hacinamiento y organización de las tareas domésticas.

```
df = crear_variables(df)
REEMPLAZADAS = ["CH03", "CH06", "CH07", "CH08", "CH12", "CH13", "CH14", "CH15",  
"CH16", "NIVEL_ED", "PP04A", "PP04B_COD",  
"PP04D_COD", "PP04C", "PP04C99", "PP04G", "PP07A", "PP04B3_MES",  
"PP04B3_ANO", "PP04B3_DIA", "VII1_1",  
"VII1_2", "VII2_1", "VII2_2", "VII2_3", "VII2_4", "ocupados_hogar",  
"mujeres_adultas_hogar"]
NUEVAS = ["edad", "anios_educ", "exp_pot", "exp_pot2", "parentesco", "estado_civil",  
"cobertura_salud",  
"lugar_nacimiento", "residencia_5_anios", "cno_caracter", "cno_jerarquia",  
"cno_tecnologia", "calificacion",  
"caes_division", "rama", "tamano_establecimiento", "sector",  
"lugar_trabajo", "antiguedad", "jornada_parcial",  
"hacinamiento", "otros_ocupados_hogar", "otras_mujeres_adultas",  
"realiza_tareas_casa",  
"servicio_domestico_hogar", "recibe_ayuda_tareas"]
candidatas = [c for c in candidatas if c not in REEMPLAZADAS] + NUEVAS
print(f"Variables candidatas tras la ingeniería: {len(candidatas)}")
```

Variables candidatas tras la ingeniería: 141

3.4 Tipos, categorías poco frecuentes y variables redundantes

- Las preguntas sí/no (1 = sí, 2 = no) pasan a 1/0; el resto de los códigos numéricos que representan categorías se tratan como **categoricos** (el código 3 no es "el triple" del código 1).
- Eliminamos las variables casi constantes (> 98% en un valor) y las que tienen más del 40% de nulos, salvo las de la pareja y el clima educativo, cuyo nulo es **estructural** (no tiene pareja o no convive con otros adultos).
- Unimos en "Otros" las categorías con menos de 100 casos.
- Si un par de variables tiene una asociación mayor a 0,90 (correlación de Pearson entre numéricas, V de Cramér entre categóricas), conservamos la más interpretable.

```
binarias, categoricas_codigo = [], []
for col in candidatas:
    if not pd.api.types.is_numeric_dtype(df[col]) or col in CONTEOS or col in NUEVAS:
        continue
    valores = set(df[col].dropna().unique())
    if valores <= {0, 1, 2} and {1, 2} <= valores:
        df[col] = df[col].map({1: 1.0, 2: 0.0})
```

```

        binarias.append(col)
    elif valores <= {0, 1}:
        binarias.append(col)
    elif valores <= {0, 5}:
        # PP07G_59: 5 = "no tiene
ningún beneficio"
        df[col] = (df[col] == 5).astype(float)
        binarias.append(col)
    else:
        categoricas_codigo.append(col)
for col in categoricas_codigo:
    df[col] = df[col].map(lambda v: f"código {int(v)}" if pd.notna(v) else np.nan)

# Variables con poca información (el nulo de la pareja y del clima educativo es
estructural)
NULO_ESTRUCTURAL = ["educ_pareja", "pareja_ocupada", "clima_educativo"]
pct_moda = pd.Series({c: df.loc[m, c].value_counts(normalize=True,
dropna=False).iloc[0] for c in candidatas})
pct_nulos = df.loc[m, candidatas].isna().mean()
poca_informacion = pct_moda[pct_moda > 0.98].index.tolist() + [c for c in
pct_nulos[pct_nulos > 0.40].index
                                if c not in
NULO_ESTRUCTURAL]
candidatas = [c for c in candidatas if c not in poca_informacion]
CATEGORICAS = [c for c in candidatas if not pd.api.types.is_numeric_dtype(df[c])]
NUMERICAS = [c for c in candidatas if c not in CATEGORICAS]

# Categorías poco frecuentes
for col in CATEGORICAS:
    conteo = df.loc[m, col].value_counts()
    df[col] = df[col].where(~df[col].isin(conteo[conteo < 100].index), "Otros")

# Variables redundantes
pares = []
corr = df.loc[m, NUMERICAS].corr().abs()
for i, a in enumerate(NUMERICAS):
    pares += [(a, b, corr.loc[a, b]) for b in NUMERICAS[i + 1:] if corr.loc[a, b] >
0.90]
for i, a in enumerate(CATEGORICAS):
    for b in CATEGORICAS[i + 1:]:
        v = cramers_v(df.loc[m, a].fillna("sin dato"), df.loc[m, b].fillna("sin
dato"))
        if v > 0.90:
            pares.append((a, b, v))
CONSERVAR_SIEMPRE = {"exp_pot", "exp_pot2", "rama", "caes_division", "AGLOMERADO",
"anios_educ", "PP07H", "IV2", "IX_T0T",
                    "hijos_propios_menores_6", "hijos_propios_menores_18",
"educ_pareja"}
redundantes = []
for a, b, _ in pares:
    if a in redundantes or b in redundantes or (a in CONSERVAR_SIEMPRE and b in
CONSERVAR_SIEMPRE):
        continue
    redundantes.append(a if b in CONSERVAR_SIEMPRE else b)
candidatas = [c for c in candidatas if c not in redundantes]
CATEGORICAS = [c for c in CATEGORICAS if c in candidatas]
NUMERICAS = [c for c in NUMERICAS if c in candidatas]
print("Poca información:", poca_informacion)
print("Redundantes:", redundantes)

```

```
print(f"Variables candidatas finales: {len(candidatas)} ({len(NUMERICAS)} numéricas o binarias y {len(CATEGORICAS)} categóricas)")
```

Poca información: ['CH09', 'PP07F2', 'PP07F1_2', 'PP07F1_3', 'IV6', 'IV8', 'IV12_3', 'II5_1', 'II6_1', 'II9', 'V1', 'V21_01', 'V3', 'V4', 'V5_03', 'V8', 'V9', 'V10', 'V11_02', 'V18', 'V19_A', 'V19_B', 'V21_02', 'V21_03', 'CH11', 'PP07I', 'PP09B', 'PP07I_2', 'V2_02', 'V2_03', 'V2_01']

Redundantes: ['PP03D', 'PP07G2', 'PP07G3', 'PP07G4', 'PP07G_59', 'PP07G1', 'EMPLEO', 'II1', 'II3_1', 'IX_MAYEQ10', 'edad', 'REGION', 'MAS_500']

Variables candidatas finales: 97 (62 numéricas o binarias y 35 categóricas)

Comentarios

- **Formalidad:** el descuento jubilatorio (PP07H), las vacaciones, el aguinaldo, la obra social y la variable EMPLEO miden casi lo mismo; conservamos PP07H, la definición habitual de empleo registrado.
- **Edad y experiencia:** con edad, educación y experiencia juntas la regresión tendría colinealidad perfecta; conservamos la experiencia y su cuadrado, que la ecuación de Mincer requiere.
- **Territorio:** la región y el tamaño del aglomerado están contenidos en el aglomerado.

3.5 Valores atípicos y perdidos

Atípicos. Medimos su incidencia y los gestionamos con **winsorización**: los valores fuera de los percentiles 1 y 99 se reemplazan por esos límites, calculados **solo con el período de entrenamiento** para no usar información del futuro.

```
continuas = [c for c in NUMERICAS if c not in binarias and df[c].nunique() > 10]
incidencia = df.loc[m, continuas].apply(incidencia_outliers).T
incidencia.insert(0, "asimetría", df.loc[m, continuas].skew())
en_entrenamiento = m & (df["t"] <= 5)
for col in continuas:
    df[col] = df[col].clip(df.loc[en_entrenamiento, col].quantile(0.01),
df.loc[en_entrenamiento, col].quantile(0.99))
incidencia.round(2)
```


	asimetría	% atípicos inferiores	% atípicos superiores
PP3F_TOT	3.79	0.00	15.70
PP04B2	5.86	0.00	20.15
menores_18	1.50	0.00	0.03
educ_pareja	-0.38	0.00	0.00
clima_educativo	-0.44	0.00	0.00
hijos_propios_menores_18	1.57	0.00	0.46
IX_TOT	1.39	0.00	0.55
anios_educ	-0.62	0.47	0.00
exp_pot	0.19	0.00	0.00
exp_pot2	1.06	0.00	0.00
hacinamiento	2.08	0.00	1.09

Perdidos. Medimos el porcentaje de nulos por variable y si aparecen juntos (paquete missingno).

```

perdidos = (100 * df.loc[m, candidatas].isna().mean()).sort_values(ascending=False)
con_nulos = Perdidos[Perdidos > 0].index.tolist()
msno.heatmap(df.loc[m, con_nulos], figsize=(10, 7), fontsize=9)
plt.show()
perdidos[Perdidos > 1].round(1).to_frame("% de nulos").T

```



Justificación

- **Atípicos:** la incidencia es muy baja (menos del 1,1%) salvo en las horas en otras ocupaciones y las casas en que trabaja el servicio doméstico, donde la mayoría tiene 0 y cualquier valor positivo aparece como "atípico"; no son errores. La winsorización conserva todas las observaciones y evita que unos pocos casos dominen la regresión lineal.
- **Perdidos:** casi todos son **estructurales**. La educación y la ocupación de la pareja (57%) faltan cuando la mujer no convive en pareja (el mapa de calor muestra que aparecen siempre juntas) y el clima educativo cuando no hay otros adultos. Eliminar los registros con nulos haría perder a casi todas las mujeres sin pareja. Por eso imputamos en la sección 5, después de separar los conjuntos: las numéricas con la mediana del entrenamiento y un **indicador** (`_faltante`) que conserva la información de *por qué* falta el dato; las categóricas, con "Sin dato".

3.6 Diccionario de variables

Cada variable candidata tiene una descripción y un **bloque temático** (definidos en funciones_tfm.py). Los bloques distinguen los factores **accionables** (que la persona o la empresa pueden modificar) de los **estructurales** (terreno de la política pública).

```
diccionario_final = pd.DataFrame({"variable": candidatas})
diccionario_final["descripción"] =
diccionario_final.variable.map(DESCRIPCION).fillna(diccionario_final.variable)
diccionario_final["bloque"] = diccionario_final.variable.map(bloque_de)
diccionario_final["carácter"] = diccionario_final.bloque.map(CARACTER)
diccionario_final["tipo"] = np.where(diccionario_final.variable.isin(CATEGORICAS),
"categórica",

np.where(diccionario_final.variable.isin(binarias), "binaria (1 = sí)", "numérica"))
diccionario_final.to_csv(os.path.join(ruta_repo, "modelos",
"diccionario_variables.csv"), index=False)
diccionario_final.groupby(["carácter", "bloque"]).size().to_frame("variables")
```

variables		
carácter	bloque	
Accionable (empresa y política laboral)	Condiciones de trabajo	22
Accionable (empresa)	Ocupación y empresa	13
Accionable (persona)	Capital humano	5
Estructural (política pública)	Estrategias del hogar	15
	Hogar y cuidados	18
	Territorio y migración	3
	Vivienda y hábitat	21

4. Exploración


Antes de modelar miramos cómo se relacionan con el salario relativo algunas variables centrales y dónde trabajan las asalariadas.

```
dm = df[m].copy()
orden_ed = ["Sin instrucción", "Primario incompleto", "Primario completo",
"Secundario incompleto",
"Secundario completo", "Superior incompleto", "Superior completo"]
fig, axs = plt.subplots(2, 2, figsize=(18, 11))
sns.boxplot(data=dm, x="nivel_educativo", y="y", order=orden_ed, ax=axs[0, 0],
showliers=False)
axs[0, 0].set_title("Salario relativo según nivel educativo")
axs[0, 0].tick_params(axis="x", rotation=30)
sns.boxplot(data=dm.assign(registro=dm["PP07H"].map({1: "Con descuento jubilatorio",
0: "Sin descuento"})),
x="registro", y="y", ax=axs[0, 1], showliers=False)
axs[0, 1].set_title("Salario relativo según registro del empleo")
orden_rama = dm.groupby("rama")["y"].median().sort_values().index
sns.boxplot(data=dm, y="rama", x="y", order=orden_rama, ax=axs[1, 0],
showliers=False)
axs[1, 0].set_title("Salario relativo según rama de actividad")
sns.boxplot(data=dm.assign(tareas=dm["realiza_tareas_casa"].map({1: "Realiza las
tareas de la casa", 0: "No las realiza"}),
hijos=np.where(dm["hijos_propios_menores_6"] > 0, "Con
```

```

hijos menores de 6", "Sin hijos menores de 6")),
    x="tareas", y="y", hue="hijos", ax=axes[1, 1], showfliers=False)
axes[1, 1].set_title("Salario relativo, tareas domésticas e hijos pequeños")
for ax in axes.flat:
    ax.axhline(0, ls="--", c="grey") if ax != axes[1, 0] else ax.axvline(0, ls="--",
c="grey")
plt.tight_layout()
plt.show()

```



```

# ¿Dónde trabajan las asalariadas? Treemap por rama y calificación (módulo de
Visualización avanzada)
# Primer nivel: ramas; al hacer clic en una rama se abre su composición por
calificación.
peso_rama = dm.dropna(subset=["rama"]).groupby(["rama", "calificacion"],
dropna=False)["PONDIIIO"].sum().reset_index()
peso_rama["calificacion"] = peso_rama["calificacion"].fillna("Sin dato")
# Las ramas con menos del 4% del empleo se agrupan en "Otras ramas" para que todas
las etiquetas se lean
cuota = peso_rama.groupby("rama")["PONDIIIO"].transform("sum") /
peso_rama["PONDIIIO"].sum()
peso_rama.loc[cuota < 0.04, "rama"] = "Otras ramas"
peso_rama = peso_rama.groupby(["rama", "calificacion"], as_index=False)
["PONDIIIO"].sum()
peso_rama["rama"] = peso_rama["rama"].str.replace(" y ", " y<br>", n=1, regex=False)
# etiquetas en dos líneas
fig = px.treemap(peso_rama, path=[px.Constant("Asalariadas"), "rama",
"calificacion"], values="PONDIIIO", maxdepth=2,
color="rama", color_discrete_sequence=["#264653", "#2a9d8f",
"#e9c46a", "#f4a261", "#e76f51", "#457b9d",
"#6a994e", "#b5838d",
"#bc6c25", "#8d99ae", "#9c6644"],
title="Empleo asalariado femenino por rama de actividad (1T2024-
1T2026)<br>"

```


"<sup>Haga clic en una rama para ver su composición por"

```

calificación</sup>", height=600)
fig.update_traces(texttemplate="<b>{%label}</b><br>{%percentRoot:.0%}",
textfont_size=13,
                    hovertemplate="<b>{%label}</b><br>{%percentRoot:.1%} de las
asalariadas<extra></extra>",
                    marker=dict(line=dict(color="white", width=2)),
root_color="#eef5f4")
fig.update_layout(uniformtext=dict(minsize=11, mode="hide"), margin=dict(t=80, l=10,
r=10, b=10))
fig.show()

```

Empleo asalariado femenino por rama de actividad (1T2024-1T2026)
Haga clic en una rama para ver su composición por calificación



Ranking de variables con la V de Cramér. Como en la tarea de Minería de datos, agregamos dos variables **aleatorias de control**: las que quedan por debajo de ellas no tienen relación con el salario.


```

rng = np.random.default_rng(SEMILLA)
dm["aleatorio"], dm["aleatorio2"] = rng.uniform(0, 1, len(dm)), rng.uniform(0, 1,
len(dm))
tablaCramer = pd.DataFrame(dm[candidatas + ["aleatorio", "aleatorio2"]].apply(lambda
x: cramers_v(x, dm["y"])),
                           columns=["VCramer"])
tablaCramer["descripción"] = [DESCRIPCION.get(v, v) for v in tablaCramer.index]

```

```
fig = px.bar(tablaCramer.sort_values("VCramer").tail(30), x="VCramer",
y="descripción", height=750,
            title="Relación de cada variable con el salario relativo (V de Cramér, 30 más altas)")
fig.show()
umbral = tablaCramer.loc[["aleatorio", "aleatorio2"], "VCramer"].max()
print("Variables por debajo de los aleatorios de control:",
tablaCramer[tablaCramer.VCramer <= umbral].index.tolist())
```

Relación de cada variable con el salario relativo (V de Cramér, 30 más altas)



Variables por debajo de los aleatorios de control: ['aleatorio', 'aleatorio2']

Observaciones

- El salario relativo sube con el nivel educativo; el salto mayor es el del superior completo. El empleo registrado se asocia con salarios horarios claramente más altos.

- El empleo femenino se concentra en enseñanza, salud, comercio y servicio doméstico, ramas con niveles salariales muy distintos: el servicio doméstico está en el extremo inferior.
- La relación con las tareas domésticas y los hijos pequeños es débil a simple vista; la sección 7.3 muestra que el costo de los cuidados no aparece en el salario *por hora* sino en las horas y en la decisión de trabajar.
- La V de Cramér ubica arriba a la **formalidad**, el **servicio doméstico** y la **ocupación y actividad**. Todas las candidatas superan a los aleatorios de control. Como es una medida univariante (no tiene en cuenta que muchas variables dicen lo mismo), la selección final se hace con los modelos.

5. Modelado predictivo

5.1 Partición temporal, imputación y codificación

La pregunta del trabajo es si los determinantes sirven para **predecir el futuro inmediato**, por eso los conjuntos se separan **por tiempo** y no al azar:

Conjunto	Ondas	Uso
Entrenamiento	1T2024 a 2T2025 (6 trimestres)	Ajustar los modelos
Validación	3T2025 a 4T2025 (2 trimestres)	Comparar modelos, elegir variables e hiperparámetros, calibrar las bandas
Prueba	1T2026	Evaluación final con datos que ningún modelo vio

Una partición al azar mezclaría trimestres y, por el panel rotativo de la EPH (cada hogar se encuesta hasta cuatro veces), pondría a la misma mujer en entrenamiento y en prueba: el resultado sería optimista. Por eso informamos también el resultado para las mujeres "nuevas" del 1T2026.

```

entrenamiento = m & (df["t"] <= 5)
validacion = m & df["t"].isin([6, 7])
prueba = m & (df["t"] == 8)
prueba_nuevas = prueba & ~df["id_persona"].isin(set(df.loc[m & (df["t"] <= 7),
"id_persona"]))

# Imputación con la mediana del entrenamiento (+ indicador) y "Sin dato" en las
categorías
for col in NUMERICAS:
    faltantes = df[col].isna()
    if faltantes[m].mean() > 0.01:
        df[f"{col}_faltante"] = faltantes.astype(float)
        df[col] = df[col].fillna(df.loc[entrenamiento, col].median())
for col in CATEGORICAS:
    df[col] = df[col].fillna("Sin dato").astype(str)
INDICADORES = [c for c in df.columns if c.endswith("_faltante")]
VARIABLES = NUMERICAS + INDICADORES + CATEGORICAS

# One-Hot Encoding para los modelos lineales y el Random Forest; LightGBM usa las
categorías de forma nativa
X_onehot = one_hot(df[VARIABLES], CATEGORICAS)
X_cat = df[VARIABLES].copy()
for col in CATEGORICAS:
    X_cat[col] = pd.Categorical(X_cat[col], categories=sorted(df.loc[m,

```

```
col].unique()))
y, w, grupos = df["y"], df["PONDIO"], df["id_hogar"]
Xtr_oh, ytr, wtr = X_onehot[entrenamiento], y[entrenamiento], w[entrenamiento]
Xva_oh, yva, wva = X_onehot[validacion], y[validacion], w[validacion]
Xtr_cat, Xva_cat = X_cat[entrenamiento], X_cat[validacion]

pd.DataFrame({"registros": [entrenamiento.sum(), validacion.sum(), prueba.sum(),
prueba_nuevas.sum()]},
            index=["Entrenamiento", "Validación", "Prueba", "Prueba (mujeres
nuevas)"]).assign(
    variables=len(VARIABLES), **{"columnas One-Hot": X_onehot.shape[1]})
```

	registros	variables	columnas One-Hot
Entrenamiento	31092	105	302
Validación	9991	105	302
Prueba	4421	105	302
Prueba (mujeres nuevas)	2225	105	302

5.2 Comparación de modelos

Las métricas se **ponderan** con el factor de expansión PONDIO, para que representen a la población (función `saca_metricas`, como en la tarea de Machine Learning). **RMSE** y **MAE** están en puntos de log-salario (0,40 equivale a errar alrededor de un 40%); el **R²** es la proporción de la variabilidad del salario que explica el modelo. Cada modelo se registra en **MLflow**.

Modelo	Por qué
Media (línea de base)	Referencia mínima: predecir lo mismo para todas
Regresión lineal (MCO)	Ecuación de Mincer: modelo interpretable de referencia en economía laboral
Ridge y Lasso	Regresión regularizada; Lasso además selecciona variables
Árbol de decisión	Modelo no lineal simple y fácil de explicar
Random Forest	Promedia muchos árboles: robusto a atípicos e interacciones
LightGBM	<i>Gradient boosting</i> : suele ser el más preciso en datos tabulares

```
ruta_mlflow = "/content/mlflow" if EN_COLAB else os.path.abspath("mlflow_local")
os.makedirs(ruta_mlflow, exist_ok=True)
mlflow.set_tracking_uri(f"sqlite:/// {ruta_mlflow}/mlflow.db")
if mlflow.get_experiment_by_name("tfm_salarios_mujeres") is None:
    mlflow.create_experiment("tfm_salarios_mujeres",
artifact_location=os.path.join(ruta_mlflow, "artefactos"))
mlflow.set_experiment("tfm_salarios_mujeres")


MODELOS = {
    "Regresión lineal (MCO)": (LinearRegression(), "onehot"),
    "Ridge": (make_pipeline(StandardScaler(), RidgeCV(alphas=np.logspace(-3, 3,
13))), "onehot"),
    "Lasso": (make_pipeline(StandardScaler(), LassoCV(n_alphas=30, cv=3,
random_state=SEMILLA, n_jobs=-1)), "onehot"),
    "Árbol de decisión": (DecisionTreeRegressor(max_depth=10, min_samples_leaf=50,
random_state=SEMILLA), "onehot"),
    "Random Forest": (RandomForestRegressor(n_estimators=100, max_features=0.3,
min_samples_leaf=20, n_jobs=-1,
random_state=SEMILLA), "onehot"),
    "LightGBM": (lgb.LGBMRegressor(n_estimators=600, learning_rate=0.03,
num_leaves=31, min_child_samples=50,
```


```

subsample=0.8, subsample_freq=1,
colsample_bytree=0.8, random_state=SEMILLA,
verbose=-1), "categorias"),
}
resultados, entrenados = [], {}
media = np.average(ytr, weights=wtr)
resultados.append({"modelo": "Media (línea de base)", **saca_metricas(yva,
np.full(len(yva), media), wva, "Media", False)})
for nombre, (modelo, datos) in MODELOS.items():
    Xtr, Xva = (Xtr_oh, Xva_oh) if datos == "onehot" else (Xtr_cat, Xva_cat)
    with mlflow.start_run(run_name=nombre):
        if hasattr(modelo, "steps"):
            # en un pipeline el peso se pasa al
            último paso
            modelo.fit(Xtr, ytr, **{f"{modelo.steps[-1][0]}__sample_weight": wtr})
        else:
            modelo.fit(Xtr, ytr, sample_weight=wtr)
        met = saca_metricas(yva, modelo.predict(Xva), wva, nombre, graficar=nombre ==
"LightGBM")
        mlflow.log_params({"modelo": nombre, "variables": Xtr.shape[1]})
        mlflow.log_metrics({k.lower(): v for k, v in met.items()})
        entrenados[nombre] = modelo
        resultados.append({"modelo": nombre, **met})
tabla_modelos = pd.DataFrame(resultados).set_index("modelo").sort_values("R2",
ascending=False)
tabla_modelos["R2"].sort_values().plot(kind="barh", figsize=(9, 4), color="teal",
title="R² en validación (3T-4T2025)")
plt.show()
tabla_modelos.round(4)

```

Media RMSE = 0.6142 | MAE = 0.4796 | R^2 = -0.0001
 Regresión lineal (MC0) RMSE = 0.4406 | MAE = 0.3384 | R^2 = 0.4855
 Ridge RMSE = 0.4406 | MAE = 0.3384 | R^2 = 0.4855
 Lasso RMSE = 0.4400 | MAE = 0.3383 | R^2 = 0.4867
 Árbol de decisión RMSE = 0.4758 | MAE = 0.3656 | R^2 = 0.4000
 Random Forest RMSE = 0.4393 | MAE = 0.3352 | R^2 = 0.4884
 LightGBM RMSE = 0.4243 | MAE = 0.3212 | R^2 = 0.5228





	RMSE	MAE	R2
modelo			
LightGBM	0.4243	0.3212	0.5228
Random Forest	0.4393	0.3352	0.4884
Lasso	0.4400	0.3383	0.4867
Ridge	0.4406	0.3384	0.4855
Regresión lineal (MCO)	0.4406	0.3384	0.4855
Árbol de decisión	0.4758	0.3656	0.4000
Media (línea de base)	0.6142	0.4796	-0.0001

Comentarios

Todos los modelos superan con claridad a la línea de base. LightGBM es el mejor (R² de 0,52 en validación), seguido por Random Forest y los modelos lineales (0,49). La ventaja de los árboles sobre la regresión lineal es pequeña: la mayor parte de la relación entre las características y el salario es aproximadamente lineal en logaritmos, como supone la ecuación de Mincer. Ridge y Lasso quedan prácticamente igual que MCO: con decenas de miles de observaciones la regularización casi no cambia el ajuste. (En versiones anteriores probamos un *stacking* de Random Forest y LightGBM: no superaba a LightGBM solo y lo descartamos.)

5.3 Selección de variables

Dos criterios complementarios: **Lasso** (las variables con todos sus coeficientes en cero no aportan dada la información de las demás) e **importancia por permutación** de LightGBM en validación (cuánto empeora el R² si se desordena al azar cada variable). Retenemos las variables con importancia mayor a 0,001 de R² más el núcleo de la ecuación de Mincer, y comprobamos que el modelo reducido no pierde capacidad predictiva.

```
lasso = entrenados["Lasso"][-1]
coef_lasso = pd.Series(lasso.coef_, index=Xtr_oh.columns)
origen = {col: next((v for v in VARIABLES if col == v or col.startswith(v + "_")),
col) for col in Xtr_oh.columns}
lasso_por_variable = coef_lasso.abs().groupby(origen).max()

perm = permutation_importance(entrenados["LightGBM"], Xva_cat, yva,
```

```

sample_weight=wva, n_repeats=3,
                                random_state=SEMILLA, scoring="r2", n_jobs=-1)
importancia_perm = pd.Series(perm.importances_mean,
index=Xva_cat.columns).sort_values(ascending=False)
SELECCIONADAS = importancia_perm[importancia_perm > 0.001].index.tolist()
SELECCIONADAS += [v for v in ["anios_educ", "exp_pot", "exp_pot2"] if v not in
SELECCIONADAS]

# Comparación del modelo con todas las variables y con las seleccionadas
CAT_SEL = [c for c in SELECCIONADAS if c in CATEGORICAS]
Xsel_cat = X_cat[SELECCIONADAS]
Xsel_oh = one_hot(df[SELECCIONADAS], CAT_SEL)
comparacion = {}
for nombre, modelo, Xa in [("LightGBM",
lgb.LGBMRegressor(**entrenados["LightGBM"].get_params()), Xsel_cat),
("Regresión lineal (MCO)", LinearRegression(), Xsel_oh)]:
    modelo.fit(Xa[entrenamiento], ytr, sample_weight=wtr)
    comparacion[nombre] = {"R² todas": tabla_modelos.loc[nombre, "R2"],
                           "R² seleccionadas": saca_metricas(yva,
modelo.predict(Xa[validacion]), wva, nombre, False)["R2"]}
print(f"Lasso: {(lasso_por_variable == 0).sum()} de {len(lasso_por_variable)}
variables con coeficientes en cero")
print(f"Variables seleccionadas: {len(SELECCIONADAS)} de {len(VARIABLES)}")
display(pd.DataFrame(comparacion).T.round(4))
pd.DataFrame({"importancia por permutación (R²)": importancia_perm,
               "Lasso distinto de cero": [lasso_por_variable.get(v, 0) > 0 for v in
importancia_perm.index],
               "descripción": [DESCRIPCION.get(v.replace("_faltante", ""), v) for v in
importancia_perm.index]}).head(26).round(4)

```

LightGBM RMSE = 0.4303 | MAE = 0.3273 | R² = 0.5093
 Regresión lineal (MCO) RMSE = 0.4422 | MAE = 0.3410 | R² = 0.4818
 Lasso: 15 de 96 variables con coeficientes en cero
 Variables seleccionadas: 26 de 105

	R² todas	R² seleccionadas
LightGBM	0.5228	0.5093
Regresión lineal (MCO)	0.4855	0.4818

	importancia por permutación (R ²)	Lasso distinto de cero	descripción
jornada_parcial	0.0979	True	Jornada parcial (< 35 horas)
AGLOMERADO	0.0586	True	Aglomerado urbano
INTENSI	0.0366	True	Intensidad de la ocupación
caes_division	0.0340	True	Actividad del establecimiento (CAES, 2 dígitos)
anios_educ	0.0294	True	Años de educación
PP07K	0.0229	True	Comprobante de pago
cno_character	0.0214	True	Carácter de la ocupación (CNO, 2 dígitos)
PP07H	0.0153	True	Descuento jubilatorio (empleo registrado)
PP07B1_01	0.0052	True	Cobra un plan social por este trabajo
exp_pot	0.0051	True	Experiencia potencial (años)
tamano_establecimiento	0.0049	True	Personas que trabajan en el establecimiento
PP04A1	0.0045	True	Nivel del Estado (nacional, provincial, munici...
calificacion	0.0036	True	Calificación de la ocupación
parentesco	0.0034	True	Parentesco con el jefe/a de hogar
IV2	0.0021	True	Ambientes de la vivienda
PP3F_TOT	0.0017	True	Horas en otras ocupaciones
PP07F1	0.0016	True	Le dan de comer en el trabajo
IV4	0.0016	True	Cubierta del techo
V14	0.0016	True	Pidió préstamos a familiares o amigos
hijos_propios_menores_18	0.0015	True	Hijos propios menores de 18 años
servicio_domestico_hogar	0.0014	True	El hogar tiene servicio doméstico
estado_civil	0.0013	True	Estado civil
V17	0.0013	True	Vendió pertenencias
PP04B2	0.0012	False	Cantidad de casas en que trabaja (servicio dom...
antiguedad	0.0010	True	Antigüedad en el empleo (tramos de 1 a 6)
PP03K	0.0009	True	Motivo de búsqueda de otro empleo

Comentarios

Los dos criterios coinciden en lo esencial: las variables con más importancia por permutación (jornada, aglomerado, intensidad, educación, actividad, comprobante de pago, ocupación y registro) tienen coeficientes Lasso distintos de cero; Lasso anula sobre todo variables de vivienda y del hogar que repiten información. Con 26 de las 105 variables el modelo pierde apenas una centésima de R²: es más simple de explicar y más fácil de aplicar en una empresa, que no necesita recolectar decenas de datos.

5.4 Optimización y validación cruzada

Buscamos los mejores hiperparámetros de LightGBM con GridSearchCV y **validación cruzada de 5 pliegues agrupada por hogar** (GroupKFold): todas las personas de un hogar quedan en el mismo pliegue. Luego comparamos en esos pliegues el R² de la regresión lineal y de LightGBM: la **media** indica el sesgo y la **dispersión**, la varianza.

```
grilla = {"num_leaves": [15, 31], "n_estimators": [300, 600], "learning_rate":
[0.05], "min_child_samples": [50, 100]}
busqueda = GridSearchCV(lgb.LGBMRegressor(subsample=0.8, subsample_freq=1,
colsample_bytree=0.8, random_state=SEMILLA,
verbose=-1),
grilla, cv=GroupKFold(n_splits=5),
```

```


scoring="neg_root_mean_squared_error", n_jobs=-1)
busqueda.fit(Xsel_cat[entrenamiento], ytr, groups=grupos[entrenamiento],
sample_weight=wtr)
mejor = busqueda.best_estimator_
print(f"Mejores parámetros: {busqueda.best_params_}")
with mlflow.start_run(run_name="LightGBM optimizado"):
    mlflow.log_params(busqueda.best_params_)
    met_opt = saca_metricas(yva, mejor.predict(Xsel_cat[validacion]), wva, "LightGBM
optimizado (validación)", False)
    mlflow.log_metrics({k.lower(): v for k, v in met_opt.items()})

# Comparación por validación cruzada (como cross_val_lin() en el módulo de Minería de
datos)
res_cv = {nombre: cross_val_score(modelo, Xa[entrenamiento], ytr,
groups=grupos[entrenamiento], cv=GroupKFold(n_splits=5),
scoring="r2", params={"sample_weight": wtr})
for nombre, (modelo, Xa) in {"MCO (seleccionadas)": (LinearRegression(),
Xsel_oh),
"LightGBM (seleccionadas)":
(lgb.LGBMRegressor(**mejor.get_params()), Xsel_cat)}.items()}
sns.boxenplot(x="Modelo", y="R2", data=pd.DataFrame(res_cv).melt(var_name="Modelo",
value_name="R2"), palette="viridis")
plt.title("R² por pliegue de la validación cruzada agrupada por hogar")
plt.show()
pd.DataFrame(res_cv).agg(["mean", "std"]).round(3)

```

Mejores parámetros: {'learning_rate': 0.05, 'min_child_samples': 100, 'n_estimators': 300, 'num_leaves': 15}

LightGBM optimizado (validación) RMSE = 0.4271 | MAE = 0.3261 | R^2 = 0.5165



	MCO (seleccionadas)	LightGBM (seleccionadas)
mean	0.509	0.537
std	0.013	0.012

Comentarios

La combinación elegida usa árboles pequeños, lo que indica que no hace falta un modelo muy complejo. En la validación cruzada LightGBM tiene la media más alta (menor sesgo) y una dispersión entre pliegues tan baja como la de la regresión lineal: el resultado no depende de qué hogares caen en cada pliegue.

6. Evaluación en el futuro inmediato y estabilidad

6.1 Evaluación final en el 1T2026


Reentrenamos el modelo optimizado con entrenamiento + validación (1T2024-4T2025) y lo evaluamos en el 1T2026, un trimestre que no participó en ninguna decisión. Como referencia evaluamos también la regresión lineal.

```

hasta_2025 = m & (df["t"] <= 7)
final_lgbm = lgb.LGBMRegressor(**mejor.get_params()).fit(Xsel_cat[hasta_2025],
y[hasta_2025], sample_weight=w[hasta_2025])
final_mco = LinearRegression().fit(Xsel_oh[hasta_2025], y[hasta_2025],
sample_weight=w[hasta_2025])
evaluacion = []
for nombre, modelo, Xa in [("LightGBM optimizado", final_lgbm, Xsel_cat), ("Regresión
lineal (MCO)", final_mco, Xsel_oh)]:
    for conjunto, mascara in [("Prueba 1T2026", prueba), ("Prueba 1T2026 (mujeres
nuevas)", prueba_nuevas)]:
        met = saca_metricas(y[mascara], modelo.predict(Xa[mascara]), w[mascara], f"
{nombre} - {conjunto}"),
        graficar=(nombre == "LightGBM optimizado" and conjunto ==
"Prueba 1T2026"))
        evaluacion.append({"modelo": nombre, "conjunto": conjunto, **met})
EVALUACION = pd.DataFrame(evaluacion)
with mlflow.start_run(run_name="Modelo final - prueba 1T2026"):
    mlflow.log_metrics({"rmse_prueba": EVALUACION.RMSE[0], "mae_prueba":
EVALUACION.MAE[0], "r2_prueba": EVALUACION.R2[0]})
    mlflow.lightgbm.log_model(final_lgbm, name="modelo_final")
EVALUACION.round(4)

```

LightGBM optimizado - Prueba 1T2026 RMSE = 0.4578 | MAE = 0.3444 | R^2 = 0.4350



LightGBM optimizado - Prueba 1T2026 (mujeres nuevas) RMSE = 0.4643 | MAE = 0.3518 | $R^2 = 0.4045$

Regresión lineal (MCO) - Prueba 1T2026 RMSE = 0.4700 | MAE = 0.3524 | $R^2 = 0.4043$

Regresión lineal (MCO) - Prueba 1T2026 (mujeres nuevas) RMSE = 0.4762 | MAE = 0.3575 | $R^2 = 0.3736$

	modelo	conjunto	RMSE	MAE	R2
0	LightGBM optimizado	Prueba 1T2026	0.4578	0.3444	0.4350
1	LightGBM optimizado	Prueba 1T2026 (mujeres nuevas)	0.4643	0.3518	0.4045
2	Regresión lineal (MCO)	Prueba 1T2026	0.4700	0.3524	0.4043
3	Regresión lineal (MCO)	Prueba 1T2026 (mujeres nuevas)	0.4762	0.3575	0.3736

6.2 ¿Es estable el mercado de trabajo en el corto plazo?

El supuesto principal del trabajo es que la estructura del mercado laboral es estable a un año. Lo ponemos a prueba de tres maneras:

1. **Validación con origen móvil:** entrenamos con todos los trimestres anteriores a k y predecimos el trimestre k .
2. **Índice de estabilidad poblacional (PSI):** ¿cambió la composición de las asalariadas? ($< 0,10$ estable; $0,10-0,25$ cambio moderado; $> 0,25$ reentrenar).
3. **Prueba de Wald:** ¿cambiaron los efectos principales entre 2024 y 2025?

```

origen_movil = []
for k in range(4, 9):
    antes, ahora = m & (df["t"] < k), m & (df["t"] == k)
    modelo_k = lgb.LGBMRegressor(**mejor.get_params()).fit(Xsel_cat[antes], y[antes],
sample_weight=w[antes])
    mco_k = LinearRegression().fit(Xsel_oh[antes], y[antes], sample_weight=w[antes])
    for nombre, pred in [("LightGBM", modelo_k.predict(Xsel_cat[ahora])), ("MCO",
mco_k.predict(Xsel_oh[ahora]))]:
        origen_movil.append({"trimestre predicho": str(df.loc[ahora,
"periodo"].iloc[0]), "modelo": nombre,
"R2": r2_score(y[ahora], pred, sample_weight=w[ahora])})
ORIGEN_MOVIL = pd.DataFrame(origen_movil)

PSI = pd.DataFrame({str(p): {v: psi(df.loc[entrenamiento, v], df.loc[m &
(df["periodo"] == p), v]) for v in SELECCIONADAS + ["y"]}}
for p in sorted(df.loc[m & (df["t"] > 5), "periodo"].unique())})
PSI.index = [DESCRIPCION.get(v, v) for v in PSI.index]

CLAVE = [v for v in ["anios_educ", "exp_pot", "PP07H", "jornada_parcial",
"antiguedad", "PP07C"] if v in SELECCIONADAS]

```


```

datos_wald = df[m & df["AN04"].isin([2024, 2025]).copy()
datos_wald["anio_2025"] = (datos_wald["AN04"] == 2025).astype(float)
modelo_wald = smf.wls(ols_formula(SELECCIONADAS, "y", CATEGORICAS) + " + anio_2025 + " + " + ".join(f"{v}:anio_2025" for v in CLAVE),
                      data=datos_wald, weights=datos_wald["PONDIIIO"] /
                      datos_wald["PONDIIIO"].mean()).fit(
    cov_type="cluster", cov_kws={"groups": pd.factorize(datos_wald["id_hogar"])[0]})
prueba_wald = modelo_wald.wald_test(", ".join(f"{v}:anio_2025 = 0" for v in CLAVE),
scalar=True)

fig = px.line(ORIGEN_MOVIL, x="trimestre predicho", y="R2", color="modelo",
markers=True,
              title="R² al predecir cada trimestre con los anteriores (validación con
origen móvil)")
fig.show()
print(f"PSI máximo: {PSI.values.max():.3f} | Wald (H0: los efectos no cambiaron entre
2024 y 2025): "
      f"F = {float(prueba_wald.statistic):.2f}, p-valor =
{float(prueba_wald.pvalue):.4f}")
pd.DataFrame({"variable": [DESCRIPCION.get(v, v) for v in CLAVE],
              "efecto 2024 (%)": [100 * (np.exp(modelo_wald.params[v]) - 1) for v in
CLAVE],
              "efecto 2025 (%)": [100 * (np.exp(modelo_wald.params[v] +
modelo_wald.params[f"{v}:anio_2025"]) - 1) for v in CLAVE],
              "p-valor del cambio": [modelo_wald.pvalues[f"{v}:anio_2025"] for v in
CLAVE]}).round(3)

```

R² al predecir cada trimestre con los anteriores (validación con origen móvil)



PSI máximo: 0.039 | Wald (H0: los efectos no cambiaron entre 2024 y 2025): $F = 44.07$, $p\text{-valor} = 0.0000$

	variable	efecto 2024 (%)	efecto 2025 (%)	p-valor del cambio
0	Años de educación	3.525	3.041	0.175
1	Experiencia potencial (años)	0.660	0.615	0.612
2	Descuento jubilatorio (empleo registrado)	33.668	19.153	0.000
3	Jornada parcial (< 35 horas)	21.074	24.137	0.146
4	Antigüedad en el empleo (tramos de 1 a 6)	2.913	3.222	0.756

Respuestas

- **Capacidad predictiva a un año:** en el 1T2026 el modelo explica alrededor del 44% de la variabilidad del salario relativo (40% la regresión lineal), y el 40% para las mujeres que nunca vio: no depende de "recordar" a las encuestadas del panel. Estos valores son habituales en ecuaciones salariales con encuestas de hogares, que no miden la habilidad, el desempeño ni la empresa concreta.
- **Origen móvil:** el R^2 de LightGBM se mantiene entre 0,44 y 0,55 al predecir cada trimestre con los anteriores, siempre por encima de la regresión lineal.
- **PSI:** ninguna variable supera 0,10: la **composición** de las asalariadas casi no cambió.
- **Wald:** los efectos sí cambiaron. El cambio principal es la **prima del empleo registrado**, que bajó del 34% al 19% entre 2024 y 2025, en plena desinflación; la educación, la experiencia y la jornada no cambiaron de forma significativa.
- **Conclusión:** el mercado cambió más en sus "precios" que en su composición. El supuesto de estabilidad es razonable a un año, pero el modelo debe **reentrenarse cada trimestre**, con el PSI y la cobertura de las bandas como alertas.

7. ¿Qué determina el salario de las mujeres?

7.1 Ecuación de Mincer ampliada

Estimamos la regresión lineal con las variables seleccionadas y todos los trimestres, ponderada y con errores estándar agrupados por hogar. Cada coeficiente se expresa como **efecto porcentual** sobre el salario horario, $100 \times (e^{\beta} - 1)$, con las demás variables constantes. Antes comprobamos la multicolinealidad con el VIF y estimamos la ecuación clásica (educación, experiencia y registro) como referencia.

```
datos_mincer = df[m].copy()
NUM_SEL = [v for v in SELECCIONADAS if v not in CATEGORICAS]
vif = vif_modelo(ols_formula([v for v in NUM_SEL if v != "exp_pot2"], "y"),
datos_mincer)
print(f"VIF máximo de las variables numéricas: {vif['VIF'].max():.2f}")

robusto = dict(cov_type="cluster", cov_kws={"groups":
pd.factorize(datos_mincer["id_hogar"])[0]})
pesos_mincer = datos_mincer["PONDII0"] / datos_mincer["PONDII0"].mean()
mincer_base = smf.wls("y ~ anios_educ + exp_pot + exp_pot2 + PP07H",
data=datos_mincer, weights=pesos_mincer).fit(**robusto)
mincer = smf.wls(ols_formula(SELECCIONADAS, "y", CATEGORICAS), data=datos_mincer,
weights=pesos_mincer).fit(**robusto)
print(f"Ecuación clásica: R² = {mincer_base.rsquared:.3f} | educación {100 *
```

```

(np.exp(mincer_base.params['anios_educ'] - 1):.1f}% "
    f"por año | registro {100 * (np.exp(mincer_base.params['PP07H']) - 1):.0f}%")
print(f"Ecuación ampliada: n = {int(mincer.nobs):,} | R² = {mincer.rsquared:.3f} |
efectos: {len(mincer.params) - 1} "
    f"| significativos al 5%: {(mincer.pvalues.drop('Intercept') < 0.05).sum()}")


# Efectos porcentuales con su intervalo de confianza
ic = mincer.conf_int()
coeficientes = pd.DataFrame({"efecto_%": 100 * (np.exp(mincer.params) - 1),
"ic_inf_%": 100 * (np.exp(ic[0]) - 1),
                        "ic_sup_%": 100 * (np.exp(ic[1]) - 1), "p_valor":
mincer.pvalues}).drop("Intercept")
coeficientes.insert(0, "variable", [nombre_legible(t, DESCRIPCION) for t in
coeficientes.index])
significativos = coeficientes[~coeficientes.index.str.startswith("C(") &
(coeficientes.index != "exp_pot2")
                        & (coeficientes["p_valor"] <
0.05)].sort_values("efecto_%")
fig, ax = plt.subplots(figsize=(10, 0.35 * len(significativos) + 1))
ax.errorbar(significativos["efecto_%"], significativos["variable"],
            xerr=[significativos["efecto_%"] - significativos["ic_inf_%"],
significativos["ic_sup_%"] - significativos["efecto_%"]],
            fmt="o", color="teal")
ax.axvline(0, ls="--", c="grey")
ax.set(xlabel="Efecto sobre el salario horario (%)", title="Ecuación de Mincer:
efectos significativos (p < 0,05)")
plt.tight_layout()
plt.show()

```

VIF máximo de las variables numéricas: 1.57

Ecuación clásica: $R^2 = 0.327$ | educación 8.6% por año | registro 52%

Ecuación ampliada: n = 45,504 | $R^2 = 0.500$ | efectos: 143 | significativos al 5%: 77



Respuestas

- **VIF:** todos muy por debajo de 5; no hay multicolinealidad que distorsione los coeficientes.
- **Ecuación clásica:** educación, experiencia y registro explican el 33% de la variabilidad del salario relativo. Cada año de educación se asocia con un salario un 8,6% mayor y el

empleo registrado con un 52% más.

- **Ecuación ampliada:** con las 26 variables seleccionadas el R^2 sube a 0,50. Los efectos de la educación y del registro se reducen a menos de la mitad (3,4% por año y 25%): en la ecuación clásica recogían también el efecto de la ocupación, la actividad y el territorio, que van asociados a ellos. Cada tramo de antigüedad suma un 3,3%; cobrar un plan social por el trabajo se asocia con un salario un 31% menor.
- **Un resultado contraintuitivo: la jornada parcial** se paga un 23% más *por hora*. No es una paradoja: la jornada parcial femenina se concentra en docencia y salud, donde el pago por hora es alto.


7.2 Peso de cada determinante: valores SHAP

SHAP reparte cada predicción del modelo LightGBM entre las variables. El promedio de los valores absolutos ordena los determinantes por su **peso explicativo**; al agregarlos por bloque distinguimos lo accionable de lo estructural.


```
X_shap = Xsel_cat[prueba]
contribuciones = final_lgbm.predict(X_shap, pred_contrib=True)[: , :-1]
IMPORTANCIA = pd.DataFrame({"variable": X_shap.columns, "|SHAP| medio":
np.abs(contribuciones).mean(axis=0)})
IMPORTANCIA["variable_base"] = IMPORTANCIA["variable"].str.replace("_faltante", "",
regex=False)
IMPORTANCIA["descripción"] =
IMPORTANCIA["variable_base"].map(DESCRIPCION).fillna(IMPORTANCIA["variable_base"])
IMPORTANCIA["bloque"] = IMPORTANCIA["variable_base"].map(bloque_de)
IMPORTANCIA["carácter"] = IMPORTANCIA["bloque"].map(CARACTER)
IMPORTANCIA["% de la importancia"] = 100 * IMPORTANCIA["|SHAP| medio"] /
IMPORTANCIA["|SHAP| medio"].sum()
IMPORTANCIA = IMPORTANCIA.sort_values("|SHAP| medio", ascending=False)

fig = px.bar(IMPORTANCIA.head(15).iloc[:,-1], x="% de la importancia",
y="descripción", color="bloque", orientation="h",
title="Los 15 determinantes con mayor peso en el salario de las mujeres
(SHAP, 1T2026)", height=550)
fig.update_layout(yaxis_title="")
fig.show()
por_bloque = IMPORTANCIA.groupby(["carácter", "bloque"])["% de la
importancia"].sum().round(1).reset_index()
fig = px.sunburst(por_bloque, path=["carácter", "bloque"], values="% de la
importancia",
title="Peso de cada bloque: factores accionables y estructurales")
fig.show()
```

Los 15 determinantes con mayor peso en el salario de las mujeres (SHAP, 1T2026)



Peso de cada bloque: factores accionables y estructurales



Respuestas

- Los determinantes con más peso son el **aglomerado** (12% de la importancia), el **descuento jubilatorio** (10%), la **jornada parcial** (10%), los **años de educación** (10%), el **comprobante de pago** (9%; con el descuento jubilatorio, las dos caras del empleo registrado), la **actividad** del establecimiento (9%) y el **carácter de la ocupación** (7%).
- **El empleo pesa más que la formación.** El 63% de lo que explica el modelo corresponde a las condiciones del puesto (registro, jornada, ocupación, tamaño), que dependen de las empresas y de la política laboral; un **14%**, a la educación, la experiencia y la antigüedad de la trabajadora, y un **23%**, a factores estructurales (territorio, vivienda y hogar).
- SHAP y la ecuación de Mincer coinciden en el orden de los factores principales: el *machine learning* no contradice a la economía laboral, la complementa con interacciones.

7.3 Hogar y cuidados: ¿por qué los hijos pesan poco en el salario por hora?

Que los hijos tengan poco peso en el modelo **no significa que no importen**. Estudiamos tres canales por los que el hogar puede afectar los ingresos de una mujer: el **acceso al**

empleo (con todas las mujeres de 18 a 60 años), las **horas** y el **precio de la hora** (con las asalariadas, a igual educación, experiencia y aglomerado). El salario mensual es el salario por hora por las horas, así que en logaritmos su efecto es la suma de los otros dos.

```
# Canal 1: el acceso al empleo (todas las mujeres de 18 a 60 años)
pob = POBLACION_FEMENINA.rename(columns={"CH06": "edad", "anios_educ_hogar":
"anios_educ"})
pob["hijos menores de 6"] = pob["hijos_propios_menores_6"].clip(upper=2).map({0:
"Ninguno", 1: "Uno", 2: "Dos o más"})
pob["hijos_0_5"] = pob["hijos_propios_menores_6"]
pob["hijos_6_17"] = (pob["hijos_propios_menores_18"] -
pob["hijos_propios_menores_6"]).clip(lower=0)
pob["ocupada"] = (pob["ESTADO"] == 1).astype(float)
pob["horas"] = pob["PP3E_TOT"].where((pob["ESTADO"] == 1) &
pob["PP3E_TOT"].between(1, 98))
PARTICIPACION = pob.groupby("hijos menores de 6").apply(lambda g: pd.Series({
"% ocupadas": 100 * np.average(g["ocupada"], weights=g["PONDERA"]),
"horas semanales (ocupadas)": np.average(g["horas"].dropna(),
weights=g.loc[g["horas"].notna(), "PONDERA"]}))
).reindex(["Ninguno", "Uno", "Dos o más"]).round(1)
datos_part = pob.dropna(subset=["anios_educ"])
modelo_participacion = smf.wls("ocupada ~ hijos_0_5 + hijos_6_17 + anios_educ + edad
+ I(edad ** 2) + C(periodo)",
data=datos_part,
weights=datos_part["PONDERA"]).fit(cov_type="HC1")
EFECTO_PARTICIPACION = (100 * modelo_participacion.params[["hijos_0_5",
"hijos_6_17"]]).round(1).rename(
{"hijos_0_5": "Cada hijo de 0 a 5 años", "hijos_6_17": "Cada hijo de 6 a 17
años"}).to_frame(
"cambio en la probabilidad de estar ocupada (puntos %)")

# Canales 2 y 3: las horas y el precio de la hora (asalariadas, a igual educación,
experiencia y aglomerado)
dc = df[m].copy()
dc["log_horas"] = np.log(dc["PP3E_TOT"])
dc["log_mensual"] = dc["y"] + dc["log_horas"]
dc["hijos_0_5"] = dc["hijos_propios_menores_6"]
dc["hijos_6_17"] = (dc["hijos_propios_menores_18"] -
dc["hijos_propios_menores_6"]).clip(lower=0)
HOGAR_INTERES = ["hijos_0_5", "hijos_6_17", "realiza_tareas_casa", "hacinamiento",
"clima_educativo", "educ_pareja"]
regresores = (" + ".join(HOGAR_INTERES + [f"{v}_faltante" for v in HOGAR_INTERES if
f"{v}_faltante" in dc])
+ " + anios_educ + exp_pot + exp_pot2 + C(AGLOMERADO)")
filas = []
for resultado, dependiente in [("Salario por hora", "y"), ("Horas semanales",
"log_horas"), ("Salario mensual", "log_mensual")]:
modelo = smf.wls(f"{dependiente} ~ {regresores}", data=dc, weights=dc["PONDIIIO"]
/ dc["PONDIIIO"].mean()).fit(
cov_type="cluster", cov_kws={"groups": pd.factorize(dc["id_hogar"])[0]})
filas += [{"resultado": resultado, "variable": DESCRIPCION.get(v, v), "efecto
(%)": 100 * (np.exp(modelo.params[v]) - 1),
"p-valor": modelo.pvalues[v]} for v in HOGAR_INTERES]
CANALES = pd.DataFrame(filas)


display(PARTICIPACION, EFECTO_PARTICIPACION)
fig = px.bar(CANALES[CANALES["variable"].isin([DESCRIPCION[v] for v in ["hijos_0_5",
"hijos_6_17", "realiza_tareas_casa"]])],
```

```
x="variable", y="efecto (%)", color="resultado", barmode="group",
text_auto=".1f",
color_discrete_sequence=["#2a9d8f", "#e9c46a", "#e76f51"],
title="Los cuidados se pagan en horas, no en el precio de la hora
(asalariadas)")
fig.update_layout(xaxis_title="", height=450)
fig.show()
```

	% ocupadas	horas semanales (ocupadas)
hijos menores de 6		
Ninguno	64.4	32.4
Uno	60.1	31.1
Dos o más	47.6	30.6

cambio en la probabilidad de estar ocupada (puntos %)	
Cada hijo de 0 a 5 años	-6.2
Cada hijo de 6 a 17 años	-4.6

Los cuidados se pagan en horas, no en el precio de la hora (asalariadas)



Corrección del sesgo de selección (Heckman). Solo observamos el salario de las mujeres que trabajan. Si las que trabajan son distintas de las que no en características no medidas, los coeficientes están sesgados (es el mismo problema que la "inferencia de rechazados" del módulo de Scoring). El modelo de Heckman (1979) lo corrige en dos etapas (función `heckman_dos_etapas`): un probit de la probabilidad de ser asalariada con **todas** las mujeres de 18 a 60 años y la ecuación de salarios con el **inverso del ratio de Mills**. Como restricción de exclusión usamos los hijos y la situación de la pareja, que afectan la decisión de trabajar pero casi no el salario por hora.

```

heck = pob.copy()
heck["id_hogar"] = heck["CODUSU"] + "_" + heck["NRO_HOGAR"].astype(str)
heck["id_persona"] = heck["id_hogar"] + "_" + heck["COMPONENTE"].astype(str)
heck = heck.merge(df.loc[m, ["id_persona", "periodo", "y"]], on=["id_persona",
"periodo"], how="left").dropna(subset=["anios_educ"])
heck["asalariada"] = heck["y"].notna().astype(float)
heck["exp_pot"] = (heck["edad"] - heck["anios_educ"] - 6).clip(lower=0)
heck["exp_pot2"] = heck["exp_pot"] ** 2
heck["con_pareja"] = heck["pareja_ocupada"].notna().astype(float)
heck["pareja_ocupada"] = heck["pareja_ocupada"].fillna(0)
heck["AGLOMERADO"] = heck["AGLOMERADO"].astype(int).astype(str)
probit, mco_sin_corregir, mco_heckman, heck, rho = heckman_dos_etapas(
    heck, "asalariada ~ anios_educ + exp_pot + exp_pot2 + C(AGLOMERADO) + C(periodo)
+ hijos_0_5 + hijos_6_17"
    " + con_pareja + pareja_ocupada", "y ~ anios_educ + exp_pot + exp_pot2 +
C(AGLOMERADO)", "PONDERA", "id_hogar")

# Retornos sin corregir y corregidos, y salario potencial de cada grupo de mujeres
respecto de las asalariadas
HECKMAN = pd.DataFrame({
    "sin corregir (%)": [100 * (np.exp(mco_sin_corregir.params[v]) - 1) for v in
["anios_educ", "exp_pot"]] + [np.nan],
    "corregida (%)": [100 * (np.exp(mco_heckman.params[v]) - 1) for v in
["anios_educ", "exp_pot"]] + [mco_heckman.params["imr"]]},
    index=["Año de educación", "Año de experiencia (inicial)", "Inverso del ratio de
Mills (lambda)"])
heck["y_potencial"] = mco_heckman.predict(heck.assign(imr=0))
heck["grupo"] = np.select([heck["asalariada"] == 1, heck["ESTADO"] == 1],
["Asalariadas", "Otras ocupadas"], "No ocupadas")
heck["hijos menores de 6"] = heck["hijos_0_5"].clip(upper=2).map({0: "Ninguno", 1:
"Uno", 2: "Dos o más"})
potencial = heck.groupby(["grupo", "hijos menores de 6"]).apply(
    lambda g: np.average(g["y_potencial"], weights=g["PONDERA"])).unstack()
[["Ninguno", "Uno", "Dos o más"]]
asalariadas = heck["asalariada"] == 1
SALARIO_POTENCIAL = (100 * (np.exp(potencial - np.average(heck.loc[asalariadas,
"y_potencial"],
weights=heck.loc[asalariadas, "PONDERA"]))) - 1)).round(1)
print(f"rho = {rho:.2f} | lambda: p-valor = {mco_heckman.pvalues['imr']:.1e}")
display(HECKMAN.round(2))
SALARIO_POTENCIAL

```

rho = 0.95 | lambda: p-valor = 1.2e-36

	sin corregir (%)	corregida (%)
Año de educación	10.17	13.25
Año de experiencia (inicial)	2.47	5.66
Inverso del ratio de Mills (lambda)	NaN	0.82

hijos menores de 6	Ninguno	Uno	Dos o más
grupo			
Asalariadas	0.5	-1.0	-10.8
No ocupadas	-28.8	-29.8	-33.4
Otras ocupadas	-1.4	-5.9	-12.3

Interpretación

- **La maternidad pesa en el acceso al empleo.** El 64% de las mujeres sin hijos pequeños está ocupada, frente al 48% de las que tienen dos o más. A igual edad y educación, cada hijo de 0 a 5 años reduce unos 6 puntos la probabilidad de estar ocupada, y la penalización se concentra en las mujeres con menos educación.
- **Y en las horas, no en el precio de la hora.** Entre las asalariadas, cada hijo de 6 a 17 años se asocia con un 6% menos de horas y hacerse cargo de las tareas de la casa con un 12% menos, lo que se traslada casi completo al salario mensual. Las madres asalariadas no cobran menos *por hora*.
- **Hay selección positiva** ($\lambda = 0,82$, muy significativo): las que trabajan tienen características no observadas asociadas a salarios más altos. Corrigiendo, el retorno de la educación sube del 10% al 13% por año, y las mujeres que no trabajan tendrían un salario por hora un **29% menor** que las asalariadas. La correlación implícita entre los errores es alta ($\rho = 0,95$), así que el resultado depende en parte de la forma funcional del probit.
- **Implicancia:** las políticas de cuidado (jardines maternos, licencias, jornada escolar extendida) actúan sobre la participación y las horas, sobre todo de las menos educadas; para que esas mujeres se incorporen con buenos salarios hace falta combinarlas con formación. La vivienda y el hacinamiento, por su parte, son sobre todo **consecuencia** del ingreso y la educación del hogar, no una causa del salario.

8. Territorio, recursos naturales y poder de compra

El aglomerado es el determinante con más peso. Esta sección responde tres preguntas que los cuadros publicados de la EPH no responden: ¿cuánto de la diferencia salarial entre ciudades es **propiamente territorial**?, ¿cuánto queda al descontar el **costo de vida**? y ¿qué pasa en las ciudades de los **polos energéticos y mineros**?

8.1 La prima salarial de cada aglomerado: bruta, ajustada y real

- **Prima bruta:** cuánto más (o menos) cobran por hora las asalariadas del aglomerado respecto del promedio del país.
- **Prima ajustada:** el coeficiente del aglomerado en la ecuación de Mincer, es decir, la diferencia que queda **a igual educación, experiencia, ocupación, actividad, registro y hogar**.
- **Prima real:** la prima ajustada descontando el costo de vida de la región, medido con la **Canasta Básica Total (CBT)** que el INDEC valoriza cada mes en las seis regiones (es la canasta con la que se mide la pobreza). En la Patagonia la canasta cuesta alrededor de un 17% más que en el Gran Buenos Aires; en el Noroeste, un 20% menos.

```
# Prima ajustada: coeficientes del aglomerado en la ecuación de Mincer, centrados en
el promedio ponderado del país
codigo = datos_mincer["AGLOMERADO"].str.replace("código ", "").astype(int)
coef_aglomerado = pd.Series({int(t.split("código ")[1].rstrip("")): valor for t,
valor in mincer.params.items()
                             if t.startswith("C(AGLOMERADO)"))}
beta = codigo.map(coef_aglomerado).fillna(0) # el aglomerado de
referencia tiene coeficiente 0
```

```

peso = datos_mincer["PONDIIIO"]
territorio = pd.DataFrame({
    "prima bruta": datos_mincer["y"].groupby(codigo).apply(lambda s: np.average(s,
weights=peso[s.index]))
    - np.average(datos_mincer["y"], weights=peso),
    "prima ajustada": beta.groupby(codigo).first() - np.average(beta, weights=peso)})


# Nivel de precios de cada región: CBT regional respecto del promedio del país
(ponderado por las asalariadas)
canasta = pd.read_csv(os.path.join(ruta_datos, "canasta_basica_regional.csv"))
CBT = cbt_por_trimestre(canasta)
region_aglomerado = base.groupby("AGLOMERADO")["REGION"].agg(lambda s:
s.mode().iloc[0]).map(REGIONES)
df["region"] = df["AGLOMERADO"].str.replace("código ",
").astype(int).map(region_aglomerado)
df["cbt"] = df.merge(CBT, on=["periodo", "region"], how="left")["cbt"].values
promedio_pais = df[m].groupby("periodo").apply(lambda g: np.average(g["cbt"],
weights=g["PONDIIIO"]))
df["nivel_precios"] = df["cbt"] / df["periodo"].map(promedio_pais)
nivel_region = df[m].groupby("region")["nivel_precios"].mean()
territorio["región"] = territorio.index.map(region_aglomerado)
territorio["nivel de precios"] = territorio["región"].map(nivel_region)
territorio["prima real"] = territorio["prima ajustada"] - np.log(territorio["nivel de
precios"])
for col in ["prima bruta", "prima ajustada", "prima real"]:
    territorio[col] = 100 * (np.exp(territorio[col]) - 1) # en %
respecto del promedio del país

# Características del empleo femenino de cada aglomerado y ubicación para el mapa
division = base["PP04B_COD"].map(division_caes)
df["sector_recursos"] = division.isin(DIVISIONES_RECURSOS).astype(float)
territorio["% empleo registrado"] = 100 * datos_mincer.groupby(codigo).apply(lambda
g: np.average(g["PP07H"], weights=g["PONDIIIO"]))
territorio["% en minería e hidrocarburos"] = 100 * df[m].groupby(codigo).apply(
lambda g: np.average(g["sector_recursos"], weights=g["PONDIIIO"]))
territorio["asalariadas encuestadas"] = codigo.value_counts()
territorio["aglomerado"] = [AGLOMERADOS[c][0] for c in territorio.index]
territorio["lat"], territorio["lon"] = [AGLOMERADOS[c][1] for c in territorio.index],
[AGLOMERADOS[c][2] for c in territorio.index]
territorio["polo"] = territorio.index.map(POLOS).fillna("Resto del país")
TERRITORIO = territorio.round(1).sort_values("prima ajustada", ascending=False)

fig = px.scatter_geo(TERRITORIO.reset_index(), lat="lat", lon="lon", color="prima
real", size="asalariadas encuestadas",
                    hover_name="aglomerado", hover_data={"prima bruta": True, "prima
ajustada": True, "prima real": True,
                    "lat": False, "lon":
False},
                    color_continuous_scale="RdBu", color_continuous_midpoint=0,
size_max=26, projection="mercator",
                    title="Prima salarial real por aglomerado: a igual perfil y
descontando el costo de vida (%)", height=720)
fig.update_geos(fitbounds="locations", showcountries=True, showsubunits=True)
fig.show()

```


Prima salarial real por aglomerado: a igual perfil y descontando el costo de vida (%)



```
# Prima ajustada (nominal) y real: cuánto de la diferencia territorial es costo de vida
orden = TERRITORIO.sort_values("prima real")
fig = go.Figure()
for _, fila in orden.iterrows():
    fig.add_trace(go.Scatter(x=[fila["prima ajustada"], fila["prima real"]], y=[fila["aglomerado"]] * 2, mode="lines",
                             line=dict(color="lightgrey"), showlegend=False))
fig.add_trace(go.Scatter(x=orden["prima ajustada"], y=orden["aglomerado"],
mode="markers", name="A igual perfil (nominal)",
marker=dict(color="#e9c46a", size=9)))
fig.add_trace(go.Scatter(x=orden["prima real"], y=orden["aglomerado"],
mode="markers", name="A igual perfil y costo de vida",
marker=dict(color="#264653", size=9)))
fig.add_vline(x=0, line_dash="dash", line_color="grey")
fig.update_layout(title="Prima salarial por aglomerado: nominal y real (%)",
```

```
height=780, xaxis_title="%")
fig.show()
TERRITORIO.groupby("región").apply(lambda g: pd.Series({
    c: np.average(g[c], weights=g["asalariadas encuestadas"]) for c in ["prima
bruta", "prima ajustada", "prima real"]
    | {"nivel de precios": g["nivel de
precios"].iloc[0]})).round(2).sort_values("prima real")
```

Prima salarial por aglomerado: nominal y real (%)



	prima bruta	prima ajustada	prima real	nivel de precios
región				
Cuyo	-11.17	-9.69	-7.09	1.0
Noreste	-24.15	-17.40	-3.46	0.9
Pampeana	1.48	1.55	0.37	1.0
Gran Buenos Aires	7.65	3.97	1.29	1.0
Noroeste	-20.62	-16.45	1.39	0.8
Patagonia	29.79	21.54	1.72	1.2

Respuestas

- **A igual perfil, el territorio pesa mucho en pesos:** las asalariadas de la **Patagonia** cobran por hora un 22% más que el promedio del país y las del **Noreste** y el **Noroeste**, un 17% menos: casi 40 puntos entre regiones. La **Ciudad de Buenos Aires** es el caso de composición: su prima bruta (+45%) baja al 13% a igual perfil, porque sus asalariadas son más educadas y tienen empleos más calificados.
- **Pero casi toda esa diferencia es costo de vida.** Al descontar la canasta regional, la distancia entre regiones cae de casi 40 a menos de 10 puntos: la Patagonia queda apenas un 2% por encima del promedio y el Noroeste también (+1%). Las diferencias reales que quedan son **entre ciudades:** la Ciudad de Buenos Aires (+10%), Neuquén-Plottier (+9%) y Santa Rosa (+9%) pagan más de lo que cuesta vivir en ellas; San Juan (−15%), Concordia (−10%) y Mendoza (−9%), menos.
- **Para una empresa** con sucursales en varias provincias, la prima real es la referencia adecuada para fijar adicionales por zona; **para la política pública**, indica dónde la desventaja salarial es real y no solo de precios.

8.2 Polos energéticos y mineros: ¿llega la riqueza de los recursos naturales al salario de las mujeres?

Argentina vive una expansión de los hidrocarburos no convencionales (Vaca Muerta) y de la minería (litio, cobre, oro). Son sectores con muy poco empleo femenino directo, pero pueden elevar los salarios de toda la ciudad por la demanda de servicios. Comparamos la prima de los aglomerados de los polos de **hidrocarburos** (Neuquén-Plottier y Comodoro Rivadavia) y **mineros** (Catamarca, Salta, Jujuy, San Juan y Río Gallegos) con el resto del país.

```
POLOS_RESUMEN = TERRITORIO.groupby("polo").apply(lambda g: pd.Series({
    "aglomerados": ", ".join(g["aglomerado"]),
    "% de asalariadas en minería e hidrocarburos": np.average(g["% en minería e hidrocarburos"], weights=g["asalariadas encuestadas"]),
    "prima ajustada (%)": np.average(g["prima ajustada"], weights=g["asalariadas encuestadas"]),
    "prima real (%)": np.average(g["prima real"], weights=g["asalariadas encuestadas"])})).round(1)

# Escenario: ¿cuánto ganaría una asalariada de un polo minero si su ciudad alcanzara la prima REAL de los polos petroleros?
brecha_polos = ((1 + POLOS_RESUMEN.loc["Hidrocarburos", "prima real (%)"] / 100)
                / (1 + POLOS_RESUMEN.loc["Minería", "prima real (%)"] / 100) - 1)
en_minero = m & (df["t"] == 8) & df["AGLOMERADO"].str.replace("código ",
```

```

"").astype(int).map(POLOS).eq("Minería")
salario_minero = mediana_ponderada(df.loc[en_minero, "salario_horario"],
df.loc[en_minero, "PONDIIIO"]) * HORAS_MES_COMPLETO
print(f"Escenario: +{100 * brecha_polos:.0f}% de salario, unos $ {salario_minero *
brecha_polos:,.0f} más por mes a jornada "
      f"completa para la asalariada mediana de los polos mineros (1T2026)")
POLOS_RESUMEN

```

Escenario: +5% de salario, unos \$ 43,157 más por mes a jornada completa para la asalariada mediana de los polos mineros (1T2026)

	aglomerados	% de asalariadas en minería e hidrocarburos	prima ajustada (%)	prima real (%)
polo				
Hidrocarburos	Neuquén-Plottier, Comodoro Rivadavia-Rada Tilly	4.5	26.0	5.5
Minería	Río Gallegos, Gran Salta, Gran Catamarca, Gran...	0.6	-11.7	0.1
Resto del país	Ushuaia-Río Grande, Viedma-Carmen de Patagones...	0.1	-2.2	-0.5

Respuestas

- **El empleo directo es pequeño:** en los polos petroleros, 1 de cada 20 asalariadas trabaja en el sector (5% en Neuquén-Plottier); en los mineros, menos de 1 de cada 100. Si los recursos naturales mejoran el salario de las mujeres, lo hacen sobre todo de forma **indirecta**, a través del mercado de trabajo local (comercio, salud, educación, servicios a las empresas).
- **Los polos petroleros ya muestran ese efecto:** a igual perfil pagan un 26% más que el promedio del país y, aun descontando la canasta patagónica, un 5,5% más. Neuquén-Plottier (Vaca Muerta) es la ciudad con mayor prima a igual perfil y la segunda en términos reales.
- **Los polos mineros todavía no:** en pesos pagan un 12% menos que el promedio; descontando su canasta más barata quedan justo en el promedio (+0,1%), con San Juan claramente por debajo (-15%). El escenario calculado arriba muestra lo que está en juego si esas ciudades alcanzaran la prima real de los polos petroleros. **No es un pronóstico:** es la magnitud del efecto que la expansión minera debería generar para replicar la experiencia de Vaca Muerta. Monitorear la prima de estos aglomerados trimestre a trimestre permite detectar si ese efecto aparece.

8.3 ¿Alcanza el salario? El *welfare ratio* de Robert Allen

Allen (2001) midió el nivel de vida de los trabajadores como el cociente entre lo que gana un trabajador a tiempo completo y lo que cuesta sostener a una familia con una **canasta de consumo básica valorizada a precios locales**. Aplicamos su método con la canasta oficial argentina:

welfare ratio = salario horario × 172 horas (jornada completa) / (CBT regional × 3,09 adultos equivalentes)

El hogar de referencia es el "hogar tipo 2" del INDEC (una pareja con dos hijos, 3,09 adultos equivalentes), casi igual a la familia de 3 adultos equivalentes de Allen. Un valor de 1

significa que un empleo a tiempo completo con ese salario alcanza justo para que la familia no sea pobre.


¿Es lo mismo que expresar el salario en paridad de poder adquisitivo (PPA)? No. La PPA convierte monedas con un índice de precios de *todo* el consumo del país; el *welfare ratio* compara el salario con una canasta de **necesidades básicas** valorizada en cada región y cada mes. Por eso capta diferencias de costo de vida entre regiones y responde una pregunta concreta de bienestar. Cuando la línea de comparación es la línea de pobreza internacional del Banco Mundial (como en la sección 11), el *welfare ratio* es solo el salario en PPA reescalado: sirve para comparar países, no agrega información sobre el costo de vida local.

```
df["welfare_ratio"] = df["salario_horario"] * HORAS_MES_COMPLETO / (df["cbt"] *
ADULTOS_EQUIVALENTES)
mediana_wr = lambda g: mediana_ponderada(g["welfare_ratio"], g["PONDIIIO"])
debajo_de_1 = lambda g: 100 * np.average(g["welfare_ratio"] < 1,
weights=g["PONDIIIO"])

# Evolución del welfare ratio mediano: recupera el nivel real que la variable
objetivo relativa neutraliza
WR_TRIMESTRE = pd.DataFrame({"Mujeres": df[m].groupby("periodo").apply(mediana_wr),
                             "Varones": df[~m].groupby("periodo").apply(mediana_wr)})
WR_TRIMESTRE.index = WR_TRIMESTRE.index.astype(str)
fig = px.line(WR_TRIMESTRE, markers=True, labels={"value": "Welfare ratio mediano",
"periodo": ""},
              title="¿Cuántas familias tipo sostiene fuera de la pobreza un salario
mediano a jornada completa?")
fig.add_hline(y=1, line_dash="dash")
fig.show()

# Welfare ratio de las mujeres en el último año, por nivel educativo y región
ultimo_anio = m & (df["t"] >= 5)
WR_EDUCACION = df[ultimo_anio].groupby("nivel_educativo").apply(lambda g: pd.Series({
    "welfare ratio mediano": mediana_wr(g), "% que no alcanza la línea (WR < 1)":
debajo_de_1(g)})).reindex(orden_ed).round(2)
WR_REGION = df[ultimo_anio].groupby("region").apply(lambda g: pd.Series({
    "welfare ratio mediano": mediana_wr(g), "% que no alcanza la línea (WR < 1)":
debajo_de_1(g)})).round(2)
display(WR_EDUCACION.drop(index="Sin instrucción", errors="ignore"))
WR_REGION.sort_values("welfare ratio mediano")
```

¿Cuántas familias tipo sostiene fuera de la pobreza un salario mediano a jornada completa?



nivel_educativo	welfare ratio mediano	% que no alcanza la línea (WR < 1)
Primario incompleto	0.65	85.01
Primario completo	0.55	89.86
Secundario incompleto	0.58	88.89
Secundario completo	0.65	81.42
Superior incompleto	0.81	65.63
Superior completo	1.15	39.00

region	welfare ratio mediano	% que no alcanza la línea (WR < 1)
Cuyo	0.66	73.32
Noreste	0.71	72.54
Noroeste	0.75	67.60
Pampeana	0.76	68.92
Gran Buenos Aires	0.80	64.36
Patagonia	0.87	59.58

Respuestas

- **El poder de compra se recuperó, pero no alcanza.** El *welfare ratio* mediano de las asalariadas pasó de 0,51 en el 1T2024 (tras la devaluación de diciembre de 2023) a 0,81 a fines de 2025, y bajó a 0,75 en el 1T2026. Es decir: el salario mediano de una

asalariada a jornada completa cubre **tres cuartos** de la canasta básica de una familia tipo. Solo en los hogares con más de un ingreso esa familia supera la línea de pobreza.

- **La educación separa a las que sostienen una familia de las que no:** en el último año, entre 8 y 9 de cada 10 asalariadas sin estudios superiores no alcanzarían a sostener a una familia tipo fuera de la pobreza con su salario; con título superior la mediana supera la canasta (1,15), aunque el 39% sigue sin alcanzarla.
- **Por región,** el orden sigue a la prima real y no a la nominal: la Patagonia tiene el mayor *welfare ratio* (0,87) pero el Noroeste (0,75) supera a Cuyo (0,66).
- **Uso en la aplicación:** el simulador informa, para cada perfil, el *welfare ratio* del salario esperado. Es un indicador de "salario adecuado" que una empresa puede usar como piso de referencia y que ningún cuadro publicado ofrece para un perfil concreto.

9. Brecha de género y transparencia retributiva

La **Directiva (UE) 2023/970** de transparencia retributiva, que los países de la Unión debían incorporar a su legislación antes de junio de 2026, obliga a las empresas a informar su brecha salarial de género y, si una diferencia de **5% o más** en una categoría de trabajadores no se justifica con criterios objetivos, a realizar una evaluación conjunta con los representantes de los trabajadores. Argentina no tiene una norma equivalente, pero la misma lógica (comparar a igual trabajo o perfil) puede aplicarse con los datos de la EPH.

Un LightGBM entrenado **solo con varones** aprende cómo remunera el mercado a los varones. Aplicado a las mujeres, indica cuánto cobrarían si su perfil se pagara "como el de un varón": la diferencia con su salario real es la brecha **no explicada** por las características observadas.

```
v = ~m
modelo_varones = lgb.LGBMRegressor(**mejor.get_params()).fit(Xsel_cat[v], y[v],
sample_weight=w[v])
df["contrafactual"] = modelo_varones.predict(Xsel_cat)

def brechas(g_m, g_v):
    """Brecha media, explicada y no explicada (en % del salario por hora) de un grupo
    de mujeres y varones."""
    media = np.average(g_v["y"], weights=g_v["PONDIIIO"]) - np.average(g_m["y"],
weights=g_m["PONDIIIO"])
    no_explicada = np.average(g_m["contrafactual"] - g_m["y"],
weights=g_m["PONDIIIO"])
    return pd.Series({"brecha observada (%)": 100 * (np.exp(media) - 1),
                     "explicada por características (%)": 100 * (np.exp(media -
no_explicada) - 1),
                     "no explicada (%)": 100 * (np.exp(no_explicada) - 1), "mujeres
encuestadas": len(g_m)})


BRECHA = brechas(df[m], df[v])
filas = []
for col, titulo in [("calificacion", "Calificación"), ("sector", "Sector"),
("tamano_establecimiento", "Tamaño"), ("rama", "Rama")]:
    for valor, g in df[m].groupby(col):
```

```

if len(g) >= 1000 and valor not in ("Sin dato", "Otros"):
    filas.append({"grupo": f"{titulo}: {valor}", **brechas(g, df[v & (df[col]
== valor)]))
BRECHA_GRUPOS = pd.DataFrame(filas).sort_values("no explicada (%)")
fig = px.bar(BRECHA_GRUPOS, x="no explicada (%)", y="grupo", orientation="h",
height=620,
            color=BRECHA_GRUPOS["no explicada (%)"] >= 5, color_discrete_map={True:
"#e76f51", False: "#2a9d8f"}),
            title="Brecha salarial de género no explicada por grupo de trabajadores
(umbral de la Directiva: 5%)")
fig.add_vline(x=5, line_dash="dash")
fig.update_layout(showlegend=False, yaxis_title="")
fig.show()
display(BRECHA.round(1).to_frame("total"))
BRECHA_GRUPOS.round(1)

```

Brecha salarial de género no explicada por grupo de trabajadores (umbral de la Directiva: 5%)



	total
brecha observada (%)	4.8
explicada por características (%)	-1.5
no explicada (%)	6.4
mujeres encuestadas	45504.0

	grupo	brecha observada (%)	explicada por características (%)	no explicada (%)	mujeres encuestadas
17	Rama: Servicio doméstico	-8.2	0.3	-8.4	9278.0
0	Calificación: No calificada	2.6	4.4	-1.7	14627.0
11	Rama: Enseñanza	0.7	-3.2	4.0	7173.0
5	Sector: Privado	10.3	4.4	5.6	29190.0
3	Calificación: Técnica	3.5	-3.9	7.7	9042.0
4	Sector: Estatal	-0.7	-8.0	8.0	15544.0
2	Calificación: Profesional	7.1	-1.0	8.2	3782.0
8	Tamaño: Más de 40	-3.4	-10.7	8.2	13178.0
9	Rama: Administración pública	-2.6	-10.0	8.3	6277.0
13	Rama: Hoteles y restaurantes	9.2	0.8	8.4	2448.0
16	Rama: Salud y servicios sociales	13.5	3.3	9.9	5266.0
6	Tamaño: 6 a 40	-5.1	-13.8	10.1	14179.0
1	Calificación: Operativa	2.8	-8.1	11.8	17996.0
7	Tamaño: Hasta 5	-0.5	-11.4	12.3	6920.0
12	Rama: Finanzas e inmobiliarias	13.5	0.4	13.0	1068.0
10	Rama: Comercio	12.4	-1.2	13.8	5715.0
14	Rama: Industria	13.3	-0.7	14.0	1850.0
18	Rama: Servicios profesionales y empresariales	-0.3	-12.8	14.4	2617.0
15	Rama: Otros servicios	18.3	3.0	14.8	1597.0

Respuestas

- **La brecha observada es pequeña, pero engaña.** Los varones cobran por hora un 4,8% más que las mujeres. La parte explicada por las características es **negativa** (–1,5%): las asalariadas tienen en promedio *mejores* características (sobre todo más educación). Por eso la brecha **no explicada** (6,4%) es mayor que la observada y supera el umbral del 5% de la Directiva.
- **Dónde se concentra:** en el sector privado de mercado (comercio, industria, servicios profesionales y financieros: 13-15%), en la salud (10%) y en las ocupaciones operativas (12%) y profesionales (9%). En el servicio doméstico y en las ocupaciones no calificadas no hay brecha a igual perfil: son empleos casi exclusivamente femeninos o con salarios muy uniformes. Es la información que una empresa necesita para priorizar su auditoría, y la que la aplicación calcula sobre su propia nómina.
- **Cautela:** la brecha no explicada no prueba discriminación: puede reflejar factores que la encuesta no mide (antigüedad exacta, desempeño, empresa concreta).

10. Del modelo al producto: bandas salariales y aplicación

10.1 Bandas salariales

Una empresa no necesita solo un número: necesita un **rango**. Con *regresión cuantílica conformal* (Romano, Patterson y Candès, 2019) estimamos para cada perfil una banda que contiene el salario real con una probabilidad del 90%: dos LightGBM estiman los percentiles 5 y 95 (entrenamiento), la banda se ajusta con los errores del conjunto de validación y se comprueba su cobertura real en el 1T2026.

```
NIVEL = 0.90
parametros = {k: v for k, v in mejor.get_params().items() if k not in ("objective",
"alpha")}
w_norm = wtr / wtr.mean()          # con la pérdida cuantílica, los ponderadores de la
EPH sin normalizar dan valores extremos
cuantil_inf = lgb.LGBMRegressor(**parametros, objective="quantile", alpha=(1 - NIVEL)
/ 2).fit(Xsel_cat[entrenamiento], ytr, sample_weight=w_norm)
cuantil_sup = lgb.LGBMRegressor(**parametros, objective="quantile", alpha=1 - (1 -
NIVEL) / 2).fit(Xsel_cat[entrenamiento], ytr, sample_weight=w_norm)

# Ajuste conformal con el conjunto de validación
puntaje = np.maximum(cuantil_inf.predict(Xsel_cat[validacion]) - yva, yva -
cuantil_sup.predict(Xsel_cat[validacion]))
q_ajuste = float(np.quantile(puntaje, min(1.0, np.ceil((len(puntaje) + 1) * NIVEL) /
len(puntaje))), method="higher"))

# Cobertura real en el 1T2026, total y por grupos
banda_inf = cuantil_inf.predict(Xsel_cat[prueba]) - q_ajuste
banda_sup = cuantil_sup.predict(Xsel_cat[prueba]) + q_ajuste
resultado_bandas = df.loc[prueba, ["PONDII0", "calificacion", "PP07H"]].assign(
    cubre=((y[prueba] >= banda_inf) & (y[prueba] <= banda_sup)).values,
    ancho=np.exp(banda_sup - banda_inf))
cobertura = [{"grupo": "Total", "n": len(resultado_bandas), "cobertura":
np.average(resultado_bandas.cubre, weights=resultado_bandas.PONDII0),
"ancho mediano (máximo / mínimo)": resultado_bandas.ancho.median()}]
for col in ["calificacion", "PP07H"]:
    for valor, g in resultado_bandas.groupby(col):
        if len(g) >= 100:
            cobertura.append({"grupo": f"{DESCRIPCION.get(col, col)} = {valor}", "n":
len(g),
"cobertura": np.average(g.cubre, weights=g.PONDII0),
"ancho mediano (máximo / mínimo)": g.ancho.median()})
COBERTURA = pd.DataFrame(cobertura).round(3)
print(f"Ajuste conformal de la banda: {q_ajuste:+.3f} puntos de log-salario")
COBERTURA
```

Ajuste conformal de la banda: -0.021 puntos de log-salario

	grupo	n	cobertura	ancho mediano (máximo / mínimo)
0	Total	4421	0.852	3.726
1	Calificación de la ocupación = No calificada	1410	0.891	4.567
2	Calificación de la ocupación = Operativa	1887	0.840	3.407
3	Calificación de la ocupación = Profesional	351	0.805	3.798
4	Calificación de la ocupación = Técnica	771	0.841	3.332
5	Descuento jubilatorio (empleo registrado) = 0.0	1847	0.866	5.076
6	Descuento jubilatorio (empleo registrado) = 1.0	2574	0.843	3.135

Comentarios

Las bandas cubren alrededor del 85% de los salarios del 1T2026, algo menos que el 90% buscado: el mercado del 1T2026 es algo distinto del de 2025 con el que se calibraron. Esa diferencia es en sí misma una **señal de monitoreo**: si la cobertura cae, hay que recalibrar. Las bandas son más angostas para el empleo registrado, donde los salarios están más regulados por convenios.

10.2 Exportación del modelo

Guardamos en la carpeta modelos/ del repositorio todo lo que necesita la aplicación: el modelo final, los modelos de las bandas, las variables con sus descripciones, la mediana salarial y la canasta del último trimestre (para expresar las predicciones en pesos y en *welfare ratio*) y las tablas de resultados. La aplicación **no reentrena nada**: solo aplica el modelo, como ocurriría en una empresa.

Nómina de demostración. Ninguna empresa publica los salarios individuales de su personal (son datos personales protegidos por la Ley 25.326) y el producto no lo necesita: cada empresa aplica el modelo a su propia nómina. Para mostrar la auditoría funcionando armamos una nómina **simulada** con asalariadas y asalariados de la EPH del 1T2026 del sector de salud y servicios sociales, que no corresponde a ninguna empresa real.

```
def tipo_de(variable):
    return "categórica" if variable in CATEGORICAS else ("binaria" if variable in
binarias or variable.endswith("_faltante") else "numérica")

referencia = df[prueba]
paquete = {
    "modelo": final_lgbm, "cuantil_inf": cuantil_inf, "cuantil_sup": cuantil_sup,
    "ajuste_banda": q_ajuste, "nivel": NIVEL,
    "variables": SELECCIONADAS, "tipos": {v: tipo_de(v) for v in SELECCIONADAS},
    "categorias": {v: list(Xsel_cat[v].cat.categories) for v in CAT_SEL},
    "descripciones": {v: DESCRIPCION.get(v.replace("_faltante", ""), v) for v in
SELECCIONADAS},
    "bloques": {v: bloque_de(v.replace("_faltante", "")) for v in SELECCIONADAS},
    "rangos": {v: (float(df.loc[m, v].quantile(0.01)), float(df.loc[m,
v].quantile(0.99))) for v in SELECCIONADAS
                if tipo_de(v) == "numérica"},
    "valores_tipicos": {v: (referencia[v].mode().iloc[0] if v in CATEGORICAS else
float(referencia[v].median())) for v in SELECCIONADAS},
    "mediana_salario_hora": float(referencia["mediana_trimestre"].iloc[0]),
    "periodo_referencia": "1T2026", "moneda": "ARS",
```

```

    "aglomerado_region": {"código {c}": r for c, r in region_aglomerado.items()},
    "nombres_aglomerado": {"código {c}": AGLOMERADOS[c][0] for c in
region_aglomerado.index if c in AGLOMERADOS},
    "cbt_region": CBT[CBT.periodo == 20261].set_index("region")["cbt"].to_dict(),
    "adultos_equivalentes": ADULTOS_EQUIVALENTES, "horas_mes": HORAS_MES_COMPLETO,
}
ruta_modelos = os.path.join(ruta_repo, "modelos")
joblib.dump(paquete, os.path.join(ruta_modelos, "modelo_AR.joblib"))

# Tablas de resultados que muestra la aplicación
TERRITORIO.reset_index().rename(columns={"index":
"AGLOMERADO"}).to_csv(os.path.join(ruta_modelos, "prima_aglomerado.csv"),
index=False)
POLOS_RESUMEN.to_csv(os.path.join(ruta_modelos, "polos_recursos.csv"))
WR_TRIMESTRE.to_csv(os.path.join(ruta_modelos, "welfare_ratio_trimestre.csv"))
WR_EDUCACION.to_csv(os.path.join(ruta_modelos, "welfare_ratio_educacion.csv"))
WR_REGION.to_csv(os.path.join(ruta_modelos, "welfare_ratio_region.csv"))
IMPORTANCIA.to_csv(os.path.join(ruta_modelos, "importancia_shap.csv"), index=False)
PARTICIPACION.to_csv(os.path.join(ruta_modelos, "participacion_hijos.csv"))
CANALES.to_csv(os.path.join(ruta_modelos, "canales_hogar.csv"), index=False)
SALARIO_POTENCIAL.to_csv(os.path.join(ruta_modelos, "salario_potencial.csv"))
BRECHA_GRUPOS.to_csv(os.path.join(ruta_modelos, "brecha_grupos.csv"), index=False)

# Nómina de demostración (simulada): asalariadas y asalariados de salud del 1T2026
salud = df[(df["t"] == 8) & (df["rama"] == "Salud y servicios sociales")]
nomina = salud.sample(min(300, len(salud)), random_state=SEMILLA)
pd.concat([pd.Series([f"DEMO-{i:03d}" for i in range(1, len(nomina) + 1)],
index=nomina.index, name="id_persona"),
          nomina["CH04"].map({1: "Varón", 2: "Mujer"}).rename("sexo"),
nomina["salario_horario"].round(2),
          nomina[SELECCIONADAS]], axis=1).to_csv(os.path.join(ruta_modelos,
"nomina_demo_AR.csv"), index=False)

# La aplicación debe usar las mismas versiones de scikit-learn y LightGBM con que se
guardó el modelo
import plotly, sklearn
with open(os.path.join(ruta_repo, "requirements.txt"), "w") as archivo:
    archivo.write(f"pandas>={pd.__version__}\nnumpy>={np.__version__}\nscikit-learn==
{sklearn.__version__}\n"
                  f"lightgbm=={lgb.__version__}\njoblib>=
{joblib.__version__}\nplotly>={plotly.__version__}\nstreamlit>=1.46\n")

# Experimentos de MLflow en Drive y subida de los resultados a GitHub
shutil.copy(os.path.join(ruta_mlflow, "mlflow.db"), os.path.join(ruta_salida,
"mlflow.db"))
guardar_en_github("Modelo final y resultados del TFM (parte I)")
sorted(os.listdir(ruta_modelos))

```

On branch main
Your branch is up to date with 'origin/main'.

nothing to commit, working tree clean
Everything up-to-date

```
['brecha_grupos.csv',
 'canales_hogar.csv',
 'coeficientes_mincer.csv',
 'comparacion_bloques.csv',
 'comparacion_efectos.csv',
 'comparacion_paises.csv',
 'diccionario_variables.csv',
 'importancia_shap.csv',
 'modelo_AR.joblib',
 'monitoreo_psi.csv',
 'nomina_demo_AR.csv',
 'origen_movil.csv',
 'participacion_hijos.csv',
 'polos_recursos.csv',
 'prima_aglomerado.csv',
 'salario_potencial.csv',
 'welfare_ratio_educacion.csv',
 'welfare_ratio_region.csv',
 'welfare_ratio_trimestre.csv']
```

10.3 La aplicación

La aplicación (app/app.py, publicada en Streamlit Community Cloud) está pensada para una persona de recursos humanos o un funcionario, no para un especialista en datos:

Pestaña	Pregunta que responde
¿Cuánto debería cobrar?	Salario de mercado y banda del 90% para un perfil, y si ese salario alcanza para sostener a una familia (<i>welfare ratio</i>)
Auditoría de nómina	Quiénes cobran por debajo del mercado, cuánto costaría corregirlo y cuál es la brecha de género de la empresa a igual perfil, frente al umbral del 5%
Territorio y recursos	Prima salarial nominal y real de cada ciudad y de los polos energéticos y mineros
Hogar y cuidados	Cómo afectan los hijos el empleo, las horas y el salario de las mujeres
Argentina, Brasil y España	Qué factores premia cada mercado y cuánto vale el salario en cada país (parte II)

PARTE II. ARGENTINA FRENTE A BRASIL Y ESPAÑA

11. Perspectiva comparada

¿Premian los mercados de trabajo de Argentina, Brasil y España los mismos factores, y en la misma medida? Usamos **las mismas 13 variables** en las tres encuestas y la misma variable objetivo relativa (salario horario sobre la mediana del país y período), de modo que se comparan **estructuras** y no niveles en monedas distintas. Los niveles se comparan al final con la paridad de poder adquisitivo.

País	Encuesta	Organismo	Ondas	Salario
Argentina	EPH	INDEC	1T2024 a 1T2026	Neto, mes anterior
Brasil	PNAD Contínua	IBGE	1T2024 a 2T2026	Bruto habitual
España	Encuesta de Condiciones de Vida	INE	2024 y 2025	Neto anual del año anterior

11.1 Preparación de las bases de Brasil y España

Los microdatos originales suman más de 4 millones de registros. La primera vez, el notebook los reduce a una base pequeña con las **13 variables comunes** y la guarda en Drive (tarda unos 15 minutos); las ejecuciones siguientes la leen en segundos. Las funciones de preparación están en funciones_tfm.py:

- **Brasil** (preparar_brasil): los archivos de la PNAD Contínua son de **ancho fijo**; se leen con **DuckDB**, un motor SQL que procesa el texto sin cargarlo entero en memoria, con las posiciones del programa de lectura del IBGE.
- **España** (preparar_espana): la ECV tiene ficheros de adultos, personas y hogares. El ingreso es del **año anterior**, así que retenemos a quienes hoy son asalariados y lo fueron los 12 meses de ese año. En pareja: PB205 = 1. Contrato (PL141): temporal = 11 o 12; "registrado" = contrato **escrito** (11 o 21), porque el acuerdo verbal es lo más parecido al empleo no registrado latinoamericano.
- **Validación** (validar_con_ees): el mismo modelo laboral en la Encuesta de Estructura Salarial 2022, basada en las nóminas que declaran las empresas.

```
if not HAY_COMPARACION and os.path.isdir(ruta_comparacion):
    subprocess.run([sys.executable, "-m", "pip", "install", "-q", "duckdb"])
    BR = preparar_brasil(os.path.join(ruta_comparacion, "pnadc"),
                        [(a, q) for a in (2024, 2025) for q in (1, 2, 3, 4)] +
                        [(2026, 1), (2026, 2)])
    ES = preparar_espana(os.path.join(ruta_comparacion, "ecv"), [2024, 2025])
    ecv_2025 = ES[(ES.mujer == 1) & (ES.periodo == "ECV
2025")].assign(exp_pot2=lambda d: d.exp_pot ** 2)
    validar_con_ees(os.path.join(ruta_comparacion, "ees", "datos_2022.zip"),
ecv_2025).to_csv(ruta_validacion_ees)
    pd.concat([BR, ES], ignore_index=True).to_parquet(ruta_base_comun, index=False)
    HAY_COMPARACION = True
print("Base común de Brasil y España:", "disponible" if HAY_COMPARACION else "no
disponible (se omite la parte II)")
```

Base común de Brasil y España: disponible

11.2 Base común y variable objetivo

En cada país y período recortamos los extremos del salario horario y calculamos la misma variable objetivo relativa.

```
if HAY_COMPARACION:
    datos = pd.concat([base_comun_argentina(df, base["MAS_500"]),
                        pd.read_parquet(ruta_base_comun)], ignore_index=True)
    # Recorte de extremos y variable objetivo relativa por país y período
    limites = datos.groupby(["pais", "periodo"])["salario_horario"].quantile([0.005,
0.995]).unstack()
    datos = datos.join(limites, on=["pais", "periodo"])
    datos = datos[datos["salario_horario"].between(datos[0.005],
datos[0.995])].drop(columns=[0.005, 0.995])
    medianas = datos.groupby(["pais", "periodo"]).apply(lambda g:
mediana_ponderada(g["salario_horario"], g["peso"]))
    datos["y"] = np.log(datos["salario_horario"] / datos.set_index(["pais",
"periodo"]).index.map(medianas))
    datos["exp_pot2"] = datos["exp_pot"] ** 2
    datos = datos.dropna(subset=COMUNES + ["y"]).reset_index(drop=True)
```

```
display(datos.groupby(["pais", "mujer"]).size().unstack().rename(columns={0:
"varones", 1: "mujeres"}))
```

	mujer	varones	mujeres
pais			
Argentina		49872	45038
Brasil		691522	630330
España		20851	20665

11.3 ¿Cuánto premia cada factor en cada país?

La misma ecuación de Mincer en los tres países, solo con mujeres, ponderada y con errores agrupados por hogar. En España, el empleo "registrado" se aproxima con el **contrato escrito** (el acuerdo verbal es lo más parecido al empleo no registrado de América Latina).

```
if HAY_COMPARACION:
    formula = ("y ~ anos_educ + exp_pot + exp_pot2 + C(calificacion,
Treatment('media')) + C(rama) + formal + temporal"
              + " + jornada_parcial + en_pareja + menores_6 + menores_18 +
otros_ocupados + gran_ciudad")
    ETIQUETAS = {"anos_educ": "Año adicional de educación", "exp_pot": "Año de
experiencia (inicial)",
                 "C(calificacion, Treatment('media'))[T.alta]": "Ocupación calificada
(vs. media)",
                 "C(calificacion, Treatment('media'))[T.baja]": "Ocupación no
calificada (vs. media)",
                 "formal": "Empleo registrado / contrato escrito", "temporal":
"Contrato temporal",
                 "jornada_parcial": "Jornada parcial", "en_pareja": "En pareja",
"menores_6": "Cada menor de 6 en el hogar",
                 "menores_18": "Cada menor de 18 en el hogar", "otros_ocupados":
"Cada otro ocupado del hogar",
                 "gran_ciudad": "Gran ciudad"}

    filas = []
    for pais, d in datos[datos.mujer == 1].groupby("pais"):
        modelo = smf.wls(formula, data=d, weights=d.peso / d.peso.mean()).fit(
            cov_type="cluster", cov_kwds={"groups": pd.factorize(d.id_hogar)[0]})
        ic = modelo.conf_int()
        filas += [{"país": pais, "variable": etiqueta, "efecto (%)": 100 *
(np.exp(modelo.params[t]) - 1),
                  "ic_inf": 100 * (np.exp(ic.loc[t, 0]) - 1), "ic_sup": 100 *
(np.exp(ic.loc[t, 1]) - 1)}
                  for t, etiqueta in ETIQUETAS.items() if t in modelo.params]
        print(f"{pais}: n = {int(modelo.nobs):}, R² = {modelo.rsquared:.3f}")
    COEF = pd.DataFrame(filas)
    fig = go.Figure()
    for pais, color in zip(["Argentina", "Brasil", "España"], ["#1f77b4", "#2ca02c",
"#d62728"]):
        c = COEF[COEF["país"] == pais]
        fig.add_trace(go.Scatter(x=c["efecto (%)"], y=c["variable"], mode="markers",
name=pais, marker=dict(size=11, color=color),
                             error_x=dict(type="data", symmetric=False,
array=c.ic_sup - c["efecto (%)"],
                                     arrayminus=c["efecto (%)"] -
c.ic_inf)))
        fig.add_vline(x=0, line_dash="dot")
```


```
fig.update_layout(title="Mujeres asalariadas: efecto de cada factor sobre el
salario horario (% , IC 95%)", height=600)
fig.show()
TABLA_COEF = COEF.pivot_table(index="variable", columns="país", values="efecto
(%)" )
display(TABLA_COEF.round(1))
```

Argentina: n = 45,038, $R^2 = 0.399$

Brasil: n = 630,330, $R^2 = 0.474$

España: n = 20,665, $R^2 = 0.299$

Mujeres asalariadas: efecto de cada factor sobre el salario horario (% , IC 95%)



país	Argentina	Brasil	España
variable			
Año adicional de educación	5.1	5.8	3.9
Año de experiencia (inicial)	1.1	1.3	2.2
Cada menor de 18 en el hogar	0.3	-1.0	1.3
Cada menor de 6 en el hogar	1.2	3.5	-4.9
Cada otro ocupado del hogar	-4.2	-1.8	-1.3
Contrato temporal	-12.5	-15.8	-9.4
Empleo registrado / contrato escrito	43.6	34.2	16.0
En pareja	9.2	9.3	2.5
Gran ciudad	9.2	8.8	6.6
Jornada parcial	27.2	28.5	8.1
Ocupación calificada (vs. media)	20.5	65.3	33.6
Ocupación no calificada (vs. media)	-12.5	-3.6	-12.1

11.4 Capacidad predictiva, peso de cada bloque y brecha de género

En cada país entrenamos un LightGBM con los períodos iniciales y lo evaluamos en el último disponible (Argentina: 1T2026; Brasil: 1T-2T2026; España: ECV 2025). La importancia SHAP se agrega en bloques. Para Brasil usamos una muestra aleatoria de hogares, suficiente para estimar con precisión y mucho más rápida. La brecha de género se mide como en la sección 9.


```
if HAY_COMPARACION:
    BLOQUE = {"anios_educ": "Capital humano", "exp_pot": "Capital humano",
"exp_pot2": "Capital humano",
"calificacion": "Ocupación y empresa", "rama": "Ocupación y empresa",
"formal": "Condiciones de trabajo",
"temporal": "Condiciones de trabajo", "jornada_parcial": "Condiciones
de trabajo",
"en_pareja": "Hogar y cuidados", "menores_6": "Hogar y cuidados",
"menores_18": "Hogar y cuidados",
"otros_ocupados": "Hogar y cuidados", "gran_ciudad": "Territorio"}
    hogares_br = datos.loc[datos.pais == "Brasil",
"id_hogar"].drop_duplicates().sample(frac=0.2, random_state=SEMILLA)
    muestra = datos[(datos.pais != "Brasil") | datos.id_hogar.isin(hogares_br)]
    parametros_lgbm = dict(n_estimators=400, learning_rate=0.05, num_leaves=31,
min_child_samples=50, random_state=SEMILLA, verbose=-1)
    resultados_pais, bloques, filas_brecha = [], [], []
    for pais, d in muestra.groupby("pais"):
        X = d[COMUNES].astype({"calificacion": "category", "rama": "category"})
        mujeres_d, varones_d = d.mujer == 1, d.mujer == 0
        ultimo = mujeres_d & ((d["t"] == d["t"].max()) if pais == "España" else
(d["t"] >= 8))
        modelo = lgb.LGBMRegressor(**parametros_lgbm).fit(X[mujeres_d & ~ultimo],
d.y[mujeres_d & ~ultimo],
sample_weight=d.peso[mujeres_d & ~ultimo])
        resultados_pais.append({"pais": pais, "R² en el último período":
r2_score(d.y[ultimo], modelo.predict(X[ultimo]),
sample_weight=d.peso[ultimo])})
        shap_medio = np.abs(modelo.predict(X[ultimo], pred_contrib=True)[:,
```

```

:-1])).mean(axis=0)
    bloques += [{"país": pais, "bloque": BLOQUE[v], "shap": valor} for v, valor
in zip(COMUNES, shap_medio)]
    # Brecha de género: modelo entrenado solo con varones y aplicado a las
    mujeres
    modelo_v = lgb.LGBMRegressor(**parametros_lgbm).fit(X[varones_d],
d.y[varones_d], sample_weight=d.peso[varones_d])
    observada = np.average(d.y[varones_d], weights=d.peso[varones_d]) -
np.average(d.y[mujeres_d], weights=d.peso[mujeres_d])
    no_explicada = np.average(modelo_v.predict(X[mujeres_d]) - d.y[mujeres_d],
weights=d.peso[mujeres_d])
    filas_brecha.append({"país": pais, "brecha observada (%)": 100 *
(np.exp(observada) - 1),
                        "no explicada (%)": 100 * (np.exp(no_explicada) - 1)})
    RESULTADOS_PAIS = pd.DataFrame(resultados_pais).set_index("país")
    BRECHAS_PAIS = pd.DataFrame(filas_brecha).set_index("país")
    bloques = pd.DataFrame(bloques).groupby(["país", "bloque"])
["shap"].sum().reset_index()
    bloques["% de la importancia"] = 100 * bloques["shap"] / bloques.groupby("país")
["shap"].transform("sum")
    PESO = bloques.pivot_table(index="país", columns="bloque", values="% de la
importancia").round(1)
    fig = px.bar(bloques, x="país", y="% de la importancia", color="bloque",
                title="Peso de cada bloque de determinantes en el salario de las
mujeres (SHAP)")
    fig.show()
    display(RESULTADOS_PAIS.join(BRECHAS_PAIS).round(2))
    PESO

```

Peso de cada bloque de determinantes en el salario de las mujeres (SHAP)



país	R² en el último período	brecha observada (%)	no explicada (%)
Argentina	0.35	3.96	6.27
Brasil	0.53	6.34	14.98
España	0.32	6.77	11.40

11.5 Poder de compra: ¿cuánto vale el salario de una asalariada en cada país?

Para comparar niveles convertimos el salario horario mediano de las mujeres a **dólares internacionales de 2024** con la paridad de poder adquisitivo (PPA) del consumo de los hogares del Banco Mundial. El año de referencia es 2024 en los tres países: los trimestres de 2024 en Argentina y Brasil, y la ECV 2025 en España (cuyo ingreso corresponde a 2024). El Banco Mundial no publica la PPA de Argentina posterior a 2021: la extrapolamos con la inflación relativa frente a Estados Unidos. En Argentina, además, cada salario se expresa en pesos del promedio de 2024 con el IPC del INDEC, porque la inflación de ese año superó el 100%.

El *welfare ratio* internacional compara el salario anual a jornada completa (2.000 horas) con la línea de pobreza del Banco Mundial para países de ingreso medio alto (8,30 dólares PPA de 2021 por persona y día) para una familia de 3.

```

if HAY_COMPARACION:
    ppa = pd.read_csv(os.path.join(ruta_datos,
    "ppa_banco_mundial.csv")).set_index(["pais", "anio"])[ "ppa"]
    ipc = pd.read_csv(os.path.join(ruta_datos, "ipc_indec.csv")).iloc[:, :2].dropna()
    ipc = pd.Series(ipc.iloc[:, 1].values, index=pd.PeriodIndex(ipc.iloc[:,
0].str[:7], freq="M"))
    PPA_2024 = {"Argentina": ppa_argentina_2024(ppa[("Argentina", 2021)], ipc),
    "Brasil": ppa[("Brasil", 2024)],
    "España": ppa[("España", 2024)]}
    # Línea de 8,30 USD PPA 2021 llevada a dólares de 2024 con la inflación de
    Estados Unidos
    LINEA_2024 = 8.30 * 313.689 / 270.970

    def ipc_trimestre(periodo):
        """IPC promedio de los tres meses a los que se refiere el salario de la EPH
        (el mes anterior a cada entrevista)."""
        ano, tri = divmod(int(periodo), 10)
        return ipc.reindex(pd.period_range(pd.Period(f"{ano}-{3 * tri - 2:02d}", "M")
- 1, periods=3, freq="M")).mean()


    ipc_2024 = ipc[ipc.index.year == 2024].mean()
    referencia_2024 = datos[(datos.mujer == 1) & (((datos.pais != "España") &
datos.periodo.str.startswith("2024"))
| (datos.periodo == "ECV
2025"))].copy()
    es_ar = referencia_2024.pais == "Argentina"
    referencia_2024.loc[es_ar, "salario_horario"] *= ipc_2024 /
referencia_2024.loc[es_ar, "periodo"].map(ipc_trimestre)
    PODER_COMPRA = referencia_2024.groupby("pais").apply(lambda g: pd.Series({
    "salario horario mediano (moneda local de 2024)":
mediana_ponderada(g["salario_horario"], g["peso"]),
    "PPA 2024 (moneda local por dólar internacional)": PPA_2024[g.name]}))
    PODER_COMPRA["salario horario mediano (USD PPA 2024)"] = (PODER_COMPRA.iloc[:, 0]
/ PODER_COMPRA.iloc[:, 1])
    PODER_COMPRA["welfare ratio (línea de 8,30 USD PPA, familia de 3)"] = (
    PODER_COMPRA["salario horario mediano (USD PPA 2024)"] * 2000 / (LINEA_2024 *
365 * 3))
    fig = px.bar(PODER_COMPRA.reset_index(), x="pais", y="salario horario mediano
(USD PPA 2024)", text_auto=".2f",
    title="Salario horario mediano de las mujeres asalariadas en dólares
internacionales (PPA 2024)")
    fig.show()
    display(PODER_COMPRA.round(2))
    if os.path.isfile(ruta_validacion_ees):
        print("Validación de la ECV con la Encuesta de Estructura Salarial (efectos
en %):")
        display(pd.read_csv(ruta_validacion_ees, index_col=0))

    # Tablas de la comparación para la aplicación y subida a GitHub
    TABLA_COEF.to_csv(os.path.join(ruta_modelos, "comparacion_efectos.csv"))
    PESO.to_csv(os.path.join(ruta_modelos, "comparacion_bloques.csv"))

RESULTADOS_PAIS.join(BRECHAS_PAIS).join(PODER_COMPRA).to_csv(os.path.join(ruta_modelo
s, "comparacion_paises.csv"))
guardar_en_github("Resultados de la comparación con Brasil y España (parte II)")

```

Salario horario mediano de las mujeres asalariadas en dólares internacionales (PPA 2024)



pais	salario horario mediano (moneda local de 2024)	PPA 2024 (moneda local por dólar internacional)	salario horario mediano (USD PPA 2024)	welfare ratio (línea de 8,30 USD PPA, familia de 3)
Argentina	2993.58	478.22	6.26	1.19
Brasil	10.66	2.52	4.22	0.80
España	9.91	0.59	16.85	3.20

Validación de la ECV con la Encuesta de Estructura Salarial (efectos en %):

	ECV (hogares)	EES 2022 (empresas)
Año adicional de educación	4.3	4.2
Ocupación calificada (vs. media)	35.2	38.3
Ocupación no calificada (vs. media)	-13.2	-2.6
Contrato temporal	-12.5	-0.1
Jornada parcial	9.8	-9.3

On branch main
Your branch is up to date with 'origin/main'.

nothing to commit, working tree clean
Everything up-to-date

Comentarios

- **Los mismos factores, distinta intensidad.** En los tres países la educación, la calificación de la ocupación y las condiciones del empleo ordenan el salario de las mujeres. Cada año de educación suma un 5% en Argentina, un 6% en Brasil y un 4% en España, a igual ocupación. La escala por calificación es mucho más empinada en Brasil (una ocupación calificada paga un 65% más que una de calificación media) que en España (34%) y en Argentina (21%). España premia más la experiencia (2,2% por año, frente a 1,1-1,3%).
- **La informalidad pesa más en América Latina.** El empleo registrado paga un 44% más en Argentina y un 34% más en Brasil; en España, el contrato escrito frente al verbal, un 16%. El contrato temporal resta entre 9% (España) y 16% (Brasil).
- **La jornada parcial no significa lo mismo.** En Argentina y Brasil se paga un 27-28% más por hora porque se concentra en docencia y salud; en España el premio es mucho menor (8%) y la Encuesta de Estructura Salarial, basada en nóminas, lo muestra negativo (-9%).
- **El hogar pesa poco en el precio de la hora,** como en la sección 7.3, con una excepción: en España cada menor de 6 años en el hogar se asocia con un salario por hora un 5% menor, mientras que en Argentina y Brasil el signo es positivo (reflejo de la selección de las madres que siguen trabajando).
- **Capacidad predictiva:** con las mismas 13 variables, el modelo anticipa mejor el salario en Brasil ($R^2 = 0,53$) que en Argentina (0,35) y España (0,32). El R^2 argentino es menor que en la parte I (0,43) porque aquí se usan solo las variables comunes: es el costo de la comparabilidad.
- **Qué ordena el salario en cada país (SHAP):** en Argentina pesan sobre todo las **condiciones de trabajo** (44%: registro, contrato y jornada); en Brasil, el **capital humano** (39%); en España, la **ocupación y la empresa** (43%). Es decir: en Argentina la mayor diferencia salarial entre mujeres está en *cómo* están contratadas; en Brasil, en *cuánto* estudiaron; en España, en *qué* puesto ocupan. El hogar pesa entre el 6% y el 9% en los tres países.
- **La brecha a igual perfil supera el 5% en los tres países.** La brecha no explicada (6% en Argentina, 11% en España y 15% en Brasil) es mayor que la observada (4%, 7% y 6%), porque las asalariadas tienen mejores características que los varones. En España, donde la Directiva (UE) 2023/970 ya rige, la magnitud duplica el umbral a partir del cual una empresa debe justificar la diferencia.
- **Poder de compra:** una hora de trabajo de la asalariada mediana vale 6,3 dólares internacionales en Argentina, 4,2 en Brasil y 16,8 en España (2024). Con un empleo a jornada completa, la asalariada mediana argentina cubriría 1,2 veces la línea de pobreza internacional de una familia de tres, la brasileña 0,8 veces y la española 3,2 veces. La distancia con España es de casi tres a uno; frente a Brasil, Argentina está mejor en poder de compra aunque el salario brasileño se mide en bruto y el argentino en neto.
- **Validación con las nóminas (EES):** la ECV y la Encuesta de Estructura Salarial coinciden en el retorno de la educación (4,3% y 4,2%) y en la prima de la ocupación calificada (35% y 38%): los resultados de capital humano y ocupación de España son sólidos. Difieren en el contrato temporal y la jornada parcial, que en la ECV se miden

con el ingreso del año anterior y las horas actuales: esos dos efectos españoles deben leerse con cautela.

- **Limitaciones:** las encuestas miden el salario de forma distinta (neto mensual, bruto habitual, neto anual del año anterior), solo hay 13 variables comunes y los períodos no coinciden exactamente. En España la ECV es un panel rotativo (cada hogar permanece cuatro años), así que su R^2 en el último período es algo optimista.

En síntesis, los resultados obtenidos fueron los siguientes:

- Datos y variables: 319 variables de personas y hogares, 97 candidatas y 26 seleccionadas.
- Predicción a un año (1T2026): LightGBM $R^2 = 0,44$; regresión lineal $R^2 = 0,40$; con origen móvil, entre 0,44 y 0,55. PSI máximo 0,039; Wald $p < 0,001$.
- Principales determinantes (SHAP): Aglomerado urbano, Descuento jubilatorio (empleo registrado), Jornada parcial (< 35 horas), Años de educación, Comprobante de pago.
- Reparto de la importancia: Accionable (empresa y política laboral): 38%; Accionable (empresa): 25%; Accionable (persona): 14%; Estructural (política pública): 23%.
- Hijos: cada hijo de 0 a 5 años reduce 6,2 puntos la probabilidad de estar ocupada.
- Territorio: diferencia entre la región mejor y peor pagada a igual perfil: 39 puntos en pesos y 9 puntos descontando el costo de vida.
- Polos de recursos (prima a igual perfil): hidrocarburos +26%, minería -12%.
- Welfare ratio mediano de las asalariadas (último trimestre): 0,75 familias tipo.
- Brecha de género: observada 4,8%; no explicada 6,4% (umbral de la Directiva: 5%).
- Bandas del 90%: cobertura real en el 1T2026 = 85,2%.
- Salario horario mediano de las asalariadas (USD PPA 2024): Argentina 6,3, Brasil 4,2, España 16,8.

CONCLUSIONES

12. Conclusiones generales

Este trabajo se propuso **determinar los factores que influyen en el salario de las mujeres asalariadas en Argentina y predecir sus valores en el corto plazo**, ofreciendo una **perspectiva comparativa con Brasil y España** y desarrollando una **herramienta de referencia salarial**. Para ello, se aprovecharon los microdatos de la Encuesta Permanente de Hogares (EPH) del INDEC, lo que permitió obtener información indirecta valiosa para preguntas no cubiertas por los cuadros oficiales.

1. Determinantes del salario y su peso (parte I, Argentina):

- **Factores clave:** El análisis identificó que el territorio (aglomerado urbano), el registro del empleo (descuento jubilatorio), la jornada laboral (parcial), los años de educación y el tipo de ocupación y actividad son los principales factores que concentran el peso explicativo del salario. Cada año adicional de educación se asocia con un aumento

aproximado del 3,4% en el salario por hora, mientras que el empleo registrado implica cerca de un 25% más.

- **Empleo frente a formación:** Las condiciones del puesto de trabajo (como el registro, la jornada y la ocupación) tienen un peso significativamente mayor (63%) en la explicación de las diferencias salariales que la educación y la experiencia (14%). Los factores estructurales (territorio, vivienda, hogar) representan el 23% restante. Esto sugiere que las políticas empresariales y laborales tienen un gran impacto en la estructura salarial.
- **Hogar y cuidados:** La maternidad no reduce el salario por hora de las asalariadas, sino que afecta principalmente la probabilidad de acceder al empleo (con una reducción de 6,2 puntos porcentuales por cada hijo de 0 a 5 años) y las horas trabajadas. La corrección del sesgo de selección reveló que el retorno de la educación para las mujeres que trabajan es superior (del 10% al 13% anual).
- **Territorio y costo de vida:** Las diferencias salariales nominales entre regiones son considerables (casi 40 puntos), pero al descontar el costo de vida regional (usando la Canasta Básica Total), esta brecha se reduce a menos de 10 puntos, lo que indica que gran parte de la "ventaja patagónica" o "desventaja del Norte" se debe a los precios locales. Los polos energéticos y mineros muestran efectos distintos: mientras los petroleros ya impactan positivamente en el salario real (+5,5%), los mineros aún no lo hacen de manera significativa.
- **Welfare Ratio:** El salario mediano de una asalariada a jornada completa cubre solo tres cuartas partes de la canasta básica de una familia tipo en el último trimestre, lo que resalta la necesidad de múltiples ingresos en el hogar para superar la línea de pobreza.

2. Predicción a corto plazo y estabilidad:

- **Capacidad predictiva:** El modelo LightGBM explica alrededor del 44% de la variabilidad del salario relativo en el 1T2026, y el 40% para mujeres "nuevas" que el modelo no había visto. La regresión lineal explica un 40%. La validación con origen móvil mostró un R^2 entre 0,44 y 0,55.
- **Estabilidad del mercado:** Aunque la composición de la población asalariada se mantuvo estable (PSI máximo de 0,039), los "precios" del mercado sí cambiaron, como la prima del empleo registrado, que disminuyó significativamente entre 2024 y 2025. Esto subraya la importancia de **reentrenar el modelo cada trimestre** para mantener su relevancia y precisión.

3. Brecha de género y transparencia retributiva:

- **Brecha no explicada:** La brecha salarial observada es del 4,8%, pero la brecha no explicada por las características observadas asciende al 6,4%, superando el umbral del 5% de la Directiva (UE) 2023/970. Esta brecha se concentra en el sector privado de mercado (comercio, industria, servicios profesionales y financieros) y en ciertas ocupaciones (operativas, profesionales), lo que orienta a las empresas sobre dónde focalizar las auditorías de nómina.

4. Herramienta de referencia salarial:

- **Bandas salariales:** El modelo se traduce en una herramienta que proporciona bandas salariales con un 85% de cobertura real, siendo más estrechas en el empleo registrado debido a una mayor regulación. La herramienta permite a las empresas aplicar el modelo a su nómina para auditarla y a los organismos públicos para monitorear el mercado laboral femenino.
- **Funcionalidades de la aplicación:** La aplicación (app/app.py) permite a usuarios no especialistas en datos estimar el salario de mercado para un perfil específico, auditar la nómina de una empresa, analizar primas salariales territoriales, entender el impacto de los cuidados y comparar el mercado laboral argentino con Brasil y España.

5. Perspectiva comparada (parte II, Argentina, Brasil y España):

- **Factores comunes, intensidad diferente:** Los tres países valoran factores similares como la educación, calificación y condiciones del empleo, pero con distinta intensidad. La educación tiene un retorno del 5% en Argentina, 6% en Brasil y 4% en España. Brasil muestra una escala salarial más empinada por calificación, mientras que España premia más la experiencia.
- **Informalidad y jornada parcial:** La informalidad impacta más en América Latina, con el empleo registrado pagando 44% más en Argentina y 34% en Brasil. La jornada parcial en Argentina y Brasil se asocia con un salario por hora 27-28% mayor, concentrándose en sectores como docencia y salud, a diferencia de España.
- **Brecha de género comparada:** La brecha no explicada a igual perfil supera el 5% en los tres países (6% en Argentina, 11% en España y 15% en Brasil).
- **Poder de compra:** Una hora de trabajo de la asalariada mediana en 2024 (en USD PPA) es de 6,3 en Argentina, 4,2 en Brasil y 16,8 en España. Con un empleo a jornada completa, la asalariada mediana argentina cubriría 1,2 veces la línea de pobreza internacional, la brasileña 0,8 veces y la española 3,2 veces.

Aportes del trabajo:

- Genera información sobre el salario de mercado, la prima real de las ciudades y el impacto de los recursos naturales que no está disponible en los cuadros oficiales.
- Construye variables no preguntadas directamente en la EPH (ej. hijos propios, educación de la pareja).
- Valida la estabilidad del mercado de trabajo mediante validación fuera de tiempo, origen móvil y pruebas estadísticas.
- Ofrece una comparación internacional rigurosa utilizando las mismas variables y métricas.
- Convierte el modelo predictivo en una herramienta práctica para la gestión salarial y la auditoría de género en empresas y organismos públicos.

Limitaciones: El estudio se basa en salarios declarados en encuestas de hogares urbanas, abarca un período corto de fuerte cambio macroeconómico, y los efectos son asociaciones no causales. La corrección de Heckman depende de las restricciones de exclusión, y la canasta regional mide el costo de vida para hogares de ingresos bajos y medios.

Líneas futuras: el análisis podría extenderse a nuevas ondas de la EPH para estudiar los cambios en los determinantes y del welfare ratio. También se podría seguir trimestre a trimestre la prima de los polos mineros e incorporar registros administrativos (SIPA) para medir la empresa concreta.



Determinantes y predicción del salario de las mujeres asalariadas en Argentina

Una herramienta de referencia salarial para las mujeres asalariadas de Argentina, construida con los microdatos de la Encuesta Permanente de Hogares, validada en el futuro inmediato y comparada con Brasil y España.

Aplicación: tfm-olguin-patricia.streamlit.app

Repositorio: github.com/peolguin/TFM-Olguin-Patricia

Datos: drive.google.com/drive/folders/1z812oAmY-nK_2uj-UJn6aJZZK1XbdWo9